

UNIVERSIDADE FEDERAL DE UBERLÂNDIA

Marcos Rodrigues de Oliveira Júnior

**Auditoria de Sistemas de Inteligência Artificial
em Plataformas de Streaming: um Estudo
Experimental sobre Vieses e Recomendação
Musical no Spotify**

Uberlândia

2026

UNIVERSIDADE FEDERAL DE UBERLÂNDIA

Marcos Rodrigues de Oliveira Júnior

**Auditoria de Sistemas de Inteligência Artificial em
Plataformas de Streaming: um Estudo Experimental
sobre Vieses e Recomendação Musical no Spotify**

Trabalho de Conclusão de Curso apresentado
à Faculdade de Gestão e Negócios da Univer-
sidade Federal de Uberlândia, como parte dos
requisitos exigidos para a obtenção do título
de Bacharel em Gestão da Informação.

Orientador: Prof. Dr. José Eduardo Ferreira Lopes

Universidade Federal de Uberlândia – UFU

Faculdade de Gestão e Negócios – FAGEN

Bacharelado em Gestão da Informação

Uberlândia

2026

Marcos Rodrigues de Oliveira Júnior

Auditoria de Sistemas de Inteligência Artificial em Plataformas de Streaming: um Estudo Experimental sobre Vieses e Recomendação Musical no Spotify

Trabalho de Conclusão de Curso apresentado à Faculdade de Gestão e Negócios da Universidade Federal de Uberlândia, como parte dos requisitos exigidos para a obtenção do título de Bacharel em Gestão da Informação.

Trabalho aprovado. Uberlândia, ____ de _____ de 2026:

Prof. Dr. José Eduardo Ferreira Lopes
Orientador

Professor(a)
Avaliador(a) 1

Professor(a)
Avaliador(a) 2

Uberlândia
2026

Resumo

Os sistemas de recomendação algorítmica consolidaram-se como principais mediadores entre a obra musical e o ouvinte, operando como caixas-pretas cujos critérios de seleção permanecem opacos. Este trabalho audita o sistema de recomendação do Spotify sob a ótica da Gestão da Informação, investigando se a curadoria automatizada favorece a diversidade cultural ou a homogeneização do gosto musical. Adotou-se a metodologia de auditoria de caixa-preta por agentes-sonda (*sock puppet audit*), com quatro personas sintéticas de arquétipos contrastantes — *mainstream*, funcional/*lo-fi*, nostálgico e de nicho —, comparando-se os estímulos declarados (*input*) com as recomendações geradas nos *Daily Mixes* (*output*). Diante da remoção progressiva de campos da *Web API* do Spotify durante a pesquisa — fato tratado como meta-evidência da opacidade da plataforma —, os dados foram enriquecidos com as fontes externas Last.fm e MusicBrainz. Mensuraram-se a diversidade e a concentração por meio da Entropia de Shannon, da *evenness* de Pielou, do Coeficiente de Gini, do Índice Herfindahl-Hirschman e do Índice de Jaccard, com tratamento estatístico inferencial (intervalos de confiança por *bootstrap*, teste de Mann-Whitney, rarefação e teste de permutação). Os resultados revelam um fenômeno de três níveis: no conteúdo, os repertórios de artistas das personas permanecem integralmente disjuntos (Jaccard = 0, mais segregados que o acaso, $p < 0,001$); no tema, há convergência parcial de gêneros; e na magnitude, a diversidade converge por expansão de riqueza de catálogo, e não por homogeneização de entropia. Confirmam-se, ainda, um viés de popularidade (Daniel, +131% de ouvintes por artista) e um viés de *hit* dentro da cauda longa (Sofia, +405% de ouvintes por faixa). Conclui-se que o algoritmo não homogeneiza o gosto entre usuários: ele expande a riqueza interna de cada perfil e os aproxima tematicamente, mas preserva silos de conteúdo distintos.

Palavras-chave: Auditoria algorítmica. Sistemas de recomendação. Spotify. Diversidade musical. Viés de popularidade.

Abstract

Algorithmic recommender systems have become the main mediators between musical works and listeners, operating as black boxes whose selection criteria remain opaque. This study audits Spotify’s recommendation system from an Information Management perspective, investigating whether automated curation fosters cultural diversity or the homogenization of musical taste. A black-box, sock-puppet auditing methodology was adopted, using four synthetic personas of contrasting archetypes — mainstream, functional/lo-fi, nostalgic, and niche — comparing the declared stimuli (input) with the recommendations generated in the Daily Mixes (output). Given the progressive removal of fields from the Spotify Web API during the research — treated here as meta-evidence of the platform’s opacity —, the data were enriched with the external sources Last.fm and MusicBrainz. Diversity and concentration were measured through Shannon entropy, Pielou’s evenness, the Gini coefficient, the Herfindahl-Hirschman Index, and the Jaccard index, with inferential statistical treatment (bootstrap confidence intervals, the Mann-Whitney test, rarefaction, and a permutation test). The results reveal a three-level phenomenon: at the content level, the personas’ artist repertoires remain entirely disjoint (Jaccard = 0, more segregated than chance, $p < 0.001$); at the thematic level, there is partial genre convergence; and at the magnitude level, diversity converges through catalog richness expansion rather than entropy homogenization. A popularity bias (Daniel, +131% listeners per artist) and a hit bias within the long tail (Sofia, +405% listeners per track) are also confirmed. We conclude that the algorithm does not homogenize taste across users: it expands the internal richness of each profile and brings them thematically closer, while preserving distinct content silos.

Keywords: Algorithm auditing. Recommender systems. Spotify. Music diversity. Popularity bias.

Lista de ilustrações

Figura 1	– Beatriz (input): distribuição de <i>listeners</i> por faixa (Last.fm).	26
Figura 2	– Beatriz (input): distribuição de gêneros (<i>top tags</i>).	27
Figura 3	– Beatriz (input): distribuição temporal (era musical das faixas).	27
Figura 4	– Beatriz (input): concentração de artistas (Curva de Lorenz).	28
Figura 5	– Beatriz (input): popularidade vs. alcance dos artistas.	28
Figura 6	– Beatriz (input): distribuição de duração das faixas.	29
Figura 7	– Daniel (input): distribuição de <i>listeners</i> por faixa (Last.fm).	31
Figura 8	– Daniel (input): distribuição de gêneros (<i>top tags</i>).	31
Figura 9	– Daniel (input): distribuição temporal (era musical das faixas).	32
Figura 10	– Daniel (input): concentração de artistas (Curva de Lorenz).	32
Figura 11	– Daniel (input): popularidade vs. alcance dos artistas.	33
Figura 12	– Daniel (input): distribuição de duração das faixas.	33
Figura 13	– Sofia (input): distribuição de <i>listeners</i> por faixa (Last.fm).	36
Figura 14	– Sofia (input): distribuição de gêneros (<i>top tags</i>).	36
Figura 15	– Sofia (input): distribuição temporal (era musical das faixas).	37
Figura 16	– Sofia (input): concentração de artistas (Curva de Lorenz).	37
Figura 17	– Sofia (input): popularidade vs. alcance dos artistas.	38
Figura 18	– Sofia (input): distribuição de duração das faixas.	38
Figura 19	– Ricardo (input): distribuição de <i>listeners</i> por faixa (Last.fm).	41
Figura 20	– Ricardo (input): distribuição de gêneros (<i>top tags</i>).	41
Figura 21	– Ricardo (input): distribuição temporal (era musical das faixas).	42
Figura 22	– Ricardo (input): concentração de artistas (Curva de Lorenz).	42
Figura 23	– Ricardo (input): popularidade vs. alcance dos artistas.	43
Figura 24	– Ricardo (input): distribuição de duração das faixas.	43
Figura 25	– Matriz de Similaridade (Índice de Jaccard) entre as personas (input).	47
Figura 26	– Mapeamento da Economia da Atenção: popularidade vs. alcance, por persona (input).	48
Figura 27	– Cronologia do consumo: distribuição temporal das faixas por persona (KDE, input).	49
Figura 28	– Concentração de artistas: Curva de Lorenz comparada entre personas (input).	50
Figura 29	– Heatmap do Delta Algorítmico Percentual.	55
Figura 30	– Distribuição de <i>Listeners</i> por Artista (Last.fm), em escala logarítmica, <i>Input</i> vs. <i>Output</i> .	57
Figura 31	– Mediana de <i>Listeners</i> por Artista, em escala logarítmica, <i>Input</i> vs. <i>Output</i> .	58

Figura 32 – Distribuição percentual de Solo (<i>Person</i>) vs. Grupo (<i>Group</i>) entre artistas únicos.	58
Figura 33 – Distribuição temporal das faixas por persona (KDE, sobreposição <i>Input/Output</i>).	60
Figura 34 – <i>Top 10 Tags</i> por Persona, lado a lado: <i>Input</i> (azul) vs. <i>Output</i> (vermelho).	62
Figura 35 – Shannon <i>Entropy</i> de Artistas, <i>Input</i> (azul) vs. <i>Output</i> (vermelho), com delta % anotado.	65

Lista de tabelas

Tabela 1	–	Correspondência entre métricas do Spotify e substitutos externos (Last.fm/MusicBrainz)	
Tabela 2	–	Indicadores quantitativos do perfil Beatriz (input).	26
Tabela 3	–	Indicadores quantitativos do perfil Daniel (input).	30
Tabela 4	–	Indicadores quantitativos do perfil Sofia (input).	35
Tabela 5	–	Indicadores quantitativos do perfil Ricardo (input).	40
Tabela 6	–	Métricas de diversidade dos inputs (Shannon, Pielou, Gini, riqueza).	44
Tabela 7	–	Distribuição de Cauda Longa dos inputs (régua única de <i>listeners</i>).	46
Tabela 8	–	Volume e cobertura dos Outputs.	53
Tabela 9	–	Taxa de Overlap Interno entre os Daily Mixes.	54
Tabela 10	–	Delta Algorítmico Percentual (Input $\rightarrow$ Output).	56
Tabela 11	–	Jaccard médio cross-persona (6 pares) vs. nulo de permutação.	64
Tabela 12	–	Convergência da Shannon <i>Entropy</i> (e a <i>evenness</i> de Pielou).	65
Tabela 13	–	Síntese dos Achados por Persona e Hipóteses Confirmadas.	66

Lista de abreviaturas e siglas

API	<i>Application Programming Interface</i> (Interface de Programação de Aplicações)
FAGEN	Faculdade de Gestão e Negócios
HHI	<i>Herfindahl-Hirschman Index</i> (Índice Herfindahl-Hirschman)
IA	Inteligência Artificial
IC	Intervalo de Confiança
IDM	<i>Intelligent Dance Music</i>
KDE	<i>Kernel Density Estimation</i> (Estimativa de Densidade por Núcleo)
KPI	<i>Key Performance Indicator</i> (Indicador-Chave de Desempenho)
MB	MusicBrainz
MPB	Música Popular Brasileira
NLP	<i>Natural Language Processing</i> (Processamento de Linguagem Natural)
OAuth	<i>Open Authorization</i>
UFU	Universidade Federal de Uberlândia

Sumário

1	INTRODUÇÃO	11
1.1	Objetivo Geral	13
1.2	Objetivos Específicos	13
2	REFERENCIAL TEÓRICO	14
2.1	Governança algorítmica, caixa-preta e economia da atenção	14
2.2	Personalização e bolha de filtro: da hipótese à crítica	14
2.3	Viés de popularidade e a teoria da cauda longa	15
2.4	Diversidade da informação: métricas e suas armadilhas	15
2.5	Auditoria algorítmica: métodos e instrumentos	16
2.6	Estudos correlatos recentes	16
3	METODOLOGIA	17
3.1	Procedimento de Coleta e Preparação Técnica	17
3.1.1	Tratamento de Dados e Definição das Métricas de Auditoria	18
3.1.2	Síntese Estatística e Definição dos Indicadores Descritivos	19
3.1.2.1	Tratamento Estatístico Inferencial	20
3.1.3	Adaptação Metodológica: Migração para Fontes Externas (Last.fm + MusicBrainz)	21
3.2	Arquitetura dos Agentes de Teste: Caracterização das Personas Sintéticas	24
3.2.1	Beatriz (A Consumidora Mainstream)	24
3.2.2	Daniel (O Foco Instrumental/Lo-fi)	29
3.2.3	Sofia (A Consumidora de Nicho)	33
3.2.4	Ricardo (O Consumidor Nostálgico)	38
3.3	Análise Comparativa e Validação dos Estímulos (Inputs)	43
3.3.1	Métricas de Diversidade e Entropia da Informação	44
3.3.2	Distribuição de Mercado (Cauda Longa)	45
3.3.3	Análise Visual Cruzada e Topologia dos Dados	47
3.4	Síntese Metodológica e Limitações	50
3.4.1	Limitações Metodológicas e Achado Original	51
4	RESULTADOS: ANÁLISE DOS OUTPUTS E O DELTA ALGORÍTMICO	53
4.1	Apresentação dos Outputs Coletados (Daily Mixes)	53
4.2	Taxa de Overlap Interno: Redundância Intra-Persona	54

4.3	O Delta Algorítmico — Visão Geral	55
4.4	Análise Persona por Persona	56
4.4.1	Beatriz (Mainstream) — O Grupo de Controle Validado	56
4.4.2	Daniel (Lo-fi) — Confirmação do Viés de Popularidade	58
4.4.3	Sofia (Nicho) — Viés do Hit dentro da Cauda Longa	59
4.4.4	Ricardo (Nostálgico) — Pulverização da Fidelidade Canônica	60
4.5	Reconfiguração da Diversidade: Expansão de Riqueza com Manutenção de Silos	63
4.6	Síntese dos Achados e Discussão	66
4.6.1	Os Quatro Achados Centrais	66
4.6.2	Implicações Teóricas e Sociotécnicas	67
4.6.3	Limitações Específicas dos Resultados deste Capítulo	68
5	CONSIDERAÇÕES FINAIS	69
	REFERÊNCIAS	71

1 Introdução

Conforme observa [Ross \(2007, p. 15\)](#), a música adapta-se continuamente às tecnologias de cada época, acompanhando o desenvolvimento da humanidade e refletindo transformações culturais, sociais e tecnológicas. Desde os primeiros instrumentos rudimentares até as complexas produções contemporâneas, cada período histórico introduziu novas formas de criação, registro e expressão artística. Na contemporaneidade, a convergência entre a era digital e os avanços da inteligência computacional reformulou de maneira significativa não apenas os processos de produção musical, mas, sobretudo, os modos de mediação, distribuição e consumo da música.

O ambiente digital possibilitou a consolidação de mecanismos de curadoria automatizada que hoje atuam como os principais filtros entre a obra musical e o ouvinte. Nesse cenário, observa-se a substituição progressiva da curadoria humana por sistemas complexos de Inteligência Artificial, fundamentados em técnicas como Filtragem Colaborativa, Processamento de Linguagem Natural (NLP) e Redes Neurais. Essas arquiteturas permitem processar grandes volumes de dados, viabilizando a personalização de experiências sonoras em larga escala.

Sob a ótica da Gestão da Informação, essa transição caracteriza a ascensão da governança algorítmica. Plataformas como o Spotify deixaram de ser meros repositórios de arquivos para atuar como gestoras ativas de fluxos informacionais, moldando a chamada “arquitetura da escolha” de milhões de usuários. Esses sistemas operam como caixas-pretas (*black boxes*), cujos critérios de seleção permanecem proprietários e opacos, gerando assimetria informacional e limitando a compreensão do usuário sobre os processos que influenciam sua percepção cultural. O uso de Aprendizado Profundo (*Deep Learning*) permite que tais sistemas aprendam continuamente com o comportamento do usuário, tornando a auditoria algorítmica essencial para compreender se essas decisões favorecem a diversidade ou a formação de bolhas de filtro.

A evolução dessas plataformas também impactou a economia do setor musical, consolidando modelos de negócios associados à chamada Economia da Atenção. Nesse modelo, o sucesso da plataforma depende da maximização da retenção do usuário, o que frequentemente leva os algoritmos a priorizarem conteúdos de baixo risco e alta aceitação estatística. Esse processo gera um ciclo de retroalimentação no qual o conteúdo popular tende a ganhar maior visibilidade, enquanto produções novas, experimentais ou de nicho permanecem marginalizadas.

Diante desse cenário, emerge a motivação central desta pesquisa: investigar como os sistemas de recomendação influenciam a diversidade cultural. Ao priorizar padrões

estatisticamente mais consumíveis, tais algoritmos podem induzir à homogeneização do gosto musical e ao fortalecimento de bolhas de filtro (*filter bubbles*), restringindo a descoberta de nichos e o acesso a artistas independentes. O risco de alienação do gosto musical mediado por vieses algorítmicos configura-se, assim, como um objeto crítico de análise da cultura digital contemporânea.

É preciso, contudo, tratar a noção de “bolha de filtro” com rigor crítico. O conceito, popularizado por [Pariser \(2011\)](#), postula que a personalização algorítmica encerraria o usuário em um universo informacional autorreferente. Essa tese, entretanto, é objeto de controvérsia: [Bruns \(2019\)](#) argumenta que a evidência empírica robusta para bolhas de filtro é escassa e que o conceito, frequentemente, opera mais como pânico moral do que como fenômeno mensurado. Esta pesquisa posiciona-se justamente nesse debate, tomando a bolha de filtro não como pressuposto, mas como **hipótese a ser testada empiricamente** no domínio da recomendação musical — onde, como se verá no Capítulo 4, os próprios dados sugerem um comportamento mais sutil do que a metáfora clássica da bolha prevê (o algoritmo chega a *arrombar* a bolha vertical do perfil nostálgico, em vez de reforçá-la).

Nesse contexto, torna-se fundamental a realização de Auditorias Algorítmicas, que investigam exogenamente o comportamento dos sistemas por meio da análise dos *outputs* gerados a partir de estímulos controlados. A auditoria de caixa-preta permite avaliar empiricamente o viés algorítmico sem acesso ao código-fonte, contornando desafios impostos pela volatilidade dos dados e pela complexidade das interações humanas.

Embora estudos baseados em usuários reais sejam relevantes, eles frequentemente sofrem com subjetividade e inconsistência comportamental, dificultando o isolamento de variáveis estritamente algorítmicas. Para superar essa limitação, esta pesquisa propõe uma abordagem experimental automatizada baseada na mineração de dados.

Dessa forma, o estudo utiliza Personas Sintéticas como objeto central de análise. Essas personas consistem em perfis de usuários cujos hábitos de consumo são simulados por algoritmos de curadoria controlada, construídos a partir da extração de metadados via API. As identidades sintéticas — Beatriz (*Mainstream*), Daniel (*Lo-fi*), Ricardo (Nostálgico) e Sofia (Nicho) — funcionam como instrumentos de medição que isolam a variável algorítmica.

Ao analisar como o Spotify responde a essas quatro identidades musicais distintas, o estudo busca avaliar se o sistema respeita preferências musicais específicas ou se tende à padronização induzida pelo viés de popularidade. Assim, pretende-se compreender em que medida a plataforma atua como facilitadora de descobertas musicais autênticas ou como indutora de escolhas pré-determinadas pela lógica estatística do mercado global.

1.1 Objetivo Geral

Este trabalho tem como objetivo geral auditar o comportamento dos sistemas de recomendação algorítmica da plataforma Spotify, utilizando a metodologia de *Black-Box Auditing* com personas sintéticas, a fim de mensurar quantitativamente o impacto das lógicas de curadoria automatizada na diversidade cultural, na concentração de popularidade e na formação de bolhas de filtro (*filter bubbles*).

1.2 Objetivos Específicos

- Modelar e implementar quatro arquétipos de consumo musical contrastantes (*Mainstream*, Funcional, Nostálgico e *Underground*), traduzindo perfis psicográficos em *scripts* de automação para a geração de *datasets* controlados.
- Validar estatisticamente a heterogeneidade e o isolamento dos perfis iniciais (*inputs*), utilizando métricas de similaridade de conjuntos (Índice de Jaccard) e dispersão de popularidade para estabelecer uma linha de base neutra (*cold start*).
- Coletar e processar, via API do Spotify, os metadados técnicos e socioeconômicos das recomendações geradas (os seis *Daily Mixes* de cada perfil), estruturando um *corpus* de dados comparável entre os diferentes perfis.
- Mensurar a diversidade e a concentração das sugestões algorítmicas, aplicando indicadores matemáticos como a Entropia de Shannon (variedade informacional), o Coeficiente de Gini (desigualdade de distribuição) e o Índice HHI (concentração de mercado/gênero).
- Analisar o viés de popularidade e econômico, verificando se o sistema promove a “gentrificação” de gostos de nicho ao recomendar desproporcionalmente artistas “*Superstars*” (Cauda Curta) em detrimento de artistas independentes (Cauda Longa).
- Avaliar o fenômeno de Colapso de Contexto, investigando se as recomendações para perfis distintos convergem entre si — distinguindo a convergência de *conteúdo* (sobreposição de artistas, via Índice de Jaccard), de *tema* (gêneros/*tags*) e de *magnitude* de diversidade (Entropia de Shannon) — em vez de pressupor uma homogeneização única e indiferenciada.

2 Referencial Teórico

Este capítulo reúne os fundamentos teóricos que sustentam a auditoria conduzida, organizados em cinco eixos: a governança algorítmica e a economia da atenção; a controvérsia em torno da bolha de filtro; o viés de popularidade e a cauda longa; as métricas de diversidade da informação e suas armadilhas; e os métodos de auditoria algorítmica. Encerra-se com um panorama de estudos correlatos recentes.

2.1 Governança algorítmica, caixa-preta e economia da atenção

Sob a ótica da Gestão da Informação, as plataformas de *streaming* deixaram de ser meros repositórios para atuar como gestoras ativas de fluxos informacionais, exercendo o que se convencionou chamar de **governança algorítmica**: a mediação, em larga escala, das decisões de consumo cultural por sistemas automatizados de recomendação. Esses sistemas operam como **caixas-pretas** (*black boxes*), cujos critérios de seleção permanecem proprietários e opacos, gerando assimetria informacional entre a plataforma e o usuário — e também entre a plataforma e o pesquisador. [Eriksson et al. \(2019\)](#), em *Spotify Teardown*, evidenciam empiricamente essa opacidade e a resistência da plataforma ao escrutínio externo, justificando abordagens investigativas que operem “de fora para dentro”.

Essa lógica articula-se ao modelo de negócio da **economia da atenção**, no qual o sucesso da plataforma depende da maximização da retenção do usuário. Daí decorre uma tendência dos algoritmos a privilegiar conteúdos de baixo risco e alta aceitação estatística, instaurando um ciclo de retroalimentação (*feedback loop*) em que o popular ganha visibilidade enquanto produções novas, experimentais ou de nicho tendem a ser marginalizadas — pano de fundo para os vieses investigados neste trabalho.

2.2 Personalização e bolha de filtro: da hipótese à crítica

O conceito de **bolha de filtro** (*filter bubble*) foi popularizado por [Pariser \(2011\)](#), que postula que a personalização algorítmica encerraria o usuário em um universo informacional autorreferente, reduzindo a exposição ao diverso e ao contraditório. A tese, porém, é objeto de controvérsia. [Bruns \(2019\)](#) argumenta que a evidência empírica robusta para a existência de bolhas de filtro é escassa e que o conceito frequentemente opera mais como pânico moral do que como fenômeno mensurado, alertando para o risco de se atribuir à tecnologia efeitos que decorrem de dinâmicas sociais mais amplas.

Esta pesquisa posiciona-se nesse debate tomando a bolha de filtro não como pressu-

posto, mas como **hipótese a ser testada empiricamente** no domínio da recomendação musical. Como se verá, os dados sugerem um comportamento mais sutil do que a metáfora clássica prevê, exigindo distinguir a convergência de conteúdo da convergência temática.

2.3 Viés de popularidade e a teoria da cauda longa

A teoria da **cauda longa** (ANDERSON, 2006) sustenta que a digitalização ampliaria o acesso a um vasto repertório de itens de nicho, antes inviável no varejo físico. A literatura de sistemas de recomendação, contudo, documenta um **viés de popularidade** (*popularity bias*) que tensiona essa promessa: os algoritmos tendem a sobre-representar itens já populares em detrimento da cauda, prejudicando especialmente usuários de gosto *beyond-mainstream* (BAUER; SCHEDL, 2019; KOWALD; SCHEDL; LEX, 2020). Esse viés tem implicações de *fairness* não só para o usuário, mas para os fornecedores (artistas), motivando propostas de avaliação de *marketplaces* mais equilibrados (MEHROTRA et al., 2018).

No plano dos efeitos agregados, Hosanagar et al. (2014) investigam se os sistemas de recomendação fragmentam ou homogeneizam o consumo, encontrando evidências de que podem **aumentar a comunalidade** entre usuários. Tais achados situam a pergunta central deste trabalho — se o algoritmo do Spotify aproxima ou afasta perfis distintos — em uma tradição consolidada de pesquisa.

2.4 Diversidade da informação: métricas e suas armadilhas

A mensuração de diversidade apoia-se na Teoria da Informação. A **Entropia de Shannon** (SHANNON, 1948) quantifica a variedade de uma distribuição, mas é sensível tanto à *riqueza* (número de categorias) quanto à *uniformidade* (*evenness*). Para isolar a uniformidade, recorre-se à ***evenness* de Pielou** (PIELOU, 1966), que normaliza a entropia pelo seu teto teórico; e, para um tratamento unificado das ordens de diversidade, à formalização de Jost (2006). A distinção é crucial: como alertam Gotelli e Colwell (2001), comparar riqueza entre amostras de tamanhos diferentes é inválido sem padronização (rarefação), sob pena de confundir efeito real com artefato de esforço amostral — armadilha diretamente relevante a esta auditoria.

Complementam o instrumental o **Coeficiente de Gini** (desigualdade de atenção entre artistas), o **Índice Herfindahl-Hirschman** (RHOADES, 1993), originário da análise de concentração de mercado, e o **Índice de Jaccard** (similaridade entre conjuntos). No campo dos sistemas de recomendação, Vargas e Castells (2011) sistematizam métricas de novidade e diversidade sensíveis a *ranking*, oferecendo a ponte entre a Teoria da Informação e a avaliação de recomendadores.

2.5 Auditoria algorítmica: métodos e instrumentos

A **auditoria algorítmica** investiga exogenamente o comportamento de sistemas opacos pela análise de seus *outputs* sob estímulos controlados. Sandvig et al. (2014) propõem cinco desenhos de auditoria, entre os quais o *sock puppet audit* — agentes-sonda que se passam por usuários reais —, desenho adotado neste estudo. Por operar sobre saídas ruidosas, esse paradigma exige rigor inferencial: a ferramenta AdFisher (DATTA; TSCHANTZ; DATTA, 2015) recorre a testes de permutação justamente para assegurar a validade estatística de seus achados. Essas referências fundamentam tanto o desenho experimental quanto o tratamento estatístico (Seção 3.1.2.1) desta pesquisa.

2.6 Estudos correlatos recentes

No domínio específico do *streaming* musical, Anderson et al. (2020), em estudo da própria Spotify Research, medem a diversidade de consumo por *embeddings* sonoros e identificam um *trade-off* entre engajamento e diversidade — referência incontornável para o diálogo com os achados deste trabalho. A agenda mantém-se ativa: pesquisas recentes examinam o viés de popularidade em serviços comerciais (TURNBULL et al., 2022), a promoção (ou não) de música local pelos recomendadores (MATROSOVA et al., 2024) e os efeitos de escala sobre a hipótese da bolha de filtro (SHAKESPEARE; CHAREYRON; ROTH, 2025), situando esta investigação em uma discussão contemporânea e em curso.

3 Metodologia

A presente investigação adota uma abordagem de natureza experimental e descritiva, fundamentada na estratégia de Auditoria Algorítmica de Caixa-Preta (*Black-Box Auditing*). Conforme proposto por [Sandvig et al. \(2014\)](#), essa técnica possibilita a análise do comportamento de sistemas de Inteligência Artificial sem acesso ao código-fonte ou aos dados internos das plataformas, baseando-se na observação sistemática dos resultados produzidos a partir de estímulos controlados.

Paralelamente, a pesquisa recorre ao método bibliográfico com o objetivo de sustentar teoricamente a análise dos fenômenos observados. Essa revisão, conforme orientações de [Gil \(1991\)](#), abrange estudos sobre a evolução da música e o papel das tecnologias digitais. A articulação entre a auditoria algorítmica e a revisão bibliográfica permite uma compreensão abrangente do impacto da Inteligência Artificial na música contemporânea, contemplando tanto a perspectiva empírica quanto a análise teórica dos processos socio-técnicos envolvidos.

3.1 Procedimento de Coleta e Preparação Técnica

O procedimento experimental foi dividido em fases sequenciais de configuração e desenvolvimento técnico. Inicialmente, foram criadas quatro contas de utilizador distintas na plataforma Spotify, garantindo que cada perfil partisse de um estado “neutro” (*cold start*), sem histórico prévio de escuta que pudesse enviesar os resultados iniciais.

Para a automação da interação com estas contas, utilizou-se o portal Spotify for Developers para obtenção das credenciais de autenticação. O motor da pesquisa foi construído em linguagem Python, utilizando a biblioteca **Spotipy** como interface para as chamadas à API (*Application Programming Interface*) do serviço. Os códigos desenvolvidos foram responsáveis por automatizar a extração de metadados das faixas e a construção das bibliotecas personalizadas (*playlists*), garantindo que a base de dados musical de cada persona fosse estruturada de forma isolada e sistemática.

Complementarmente à automação da curadoria, foi desenvolvida uma arquitetura de análise de dados robusta para processar e auditar os resultados. O sistema integrou ferramentas de ciência de dados, como **pandas** para a estruturação tabular, e **matplotlib** e **seaborn** para a visualização gráfica. Mais do que apenas recolher listas de reprodução, o código foi programado para calcular métricas complexas de diversidade e concentração — incluindo a Entropia de Shannon, o Coeficiente de Gini e o Índice de Jaccard. Tais métricas permitem transformar a percepção subjetiva de gosto musical em dados quantitativos

auditáveis, essenciais para a verificação de vieses algorítmicos.

3.1.1 Tratamento de Dados e Definição das Métricas de Auditoria

Para transcender a análise puramente qualitativa do gosto musical, esta pesquisa implementou um *pipeline* de engenharia de dados em Python, focado na extração de indicadores matemáticos de diversidade e concentração. Os dados brutos coletados via API foram processados utilizando as bibliotecas **pandas** para estruturação tabular e **numpy** para operações vetoriais, garantindo a reprodutibilidade dos cálculos. Salvo indicação em contrário, todas as figuras e tabelas apresentadas neste trabalho são de **elaboração própria do autor (2026)**, a partir dos dados coletados via Spotify e enriquecidos com Last.fm e MusicBrainz.

A fim de quantificar fenômenos subjetivos como “ecletismo”, “bolha de filtro” e “viés de popularidade”, foram adotadas quatro métricas estatísticas fundamentais, adaptadas da Teoria da Informação e da Economia da Cultura e em diálogo com a literatura de métricas de diversidade e novidade para sistemas de recomendação ([VARGAS; CASTELLS, 2011](#)):

A) Entropia de Shannon (Diversidade Informacional)

Originalmente formulada na Teoria da Informação ([SHANNON, 1948](#)), é utilizada aqui para mensurar o grau de imprevisibilidade e variedade na curadoria de artistas. No contexto deste estudo, a Entropia (H) calcula a distribuição de frequência dos artistas dentro de uma *playlist*.

$$H(X) = - \sum_{i=1}^n p(x_i) \log_2 p(x_i)$$

onde $p(x_i)$ é a probabilidade (frequência relativa) de ocorrência do artista i . Calculada via *script* Python, valores mais altos indicam maior diversidade (*playlist* pulverizada) e valores baixos indicam alta repetição (*playlist* monótona).

B) Coeficiente de Gini (Desigualdade de Atenção)

Originalmente usado para medir desigualdade de renda, aqui o Coeficiente de Gini (G) auditou a concentração de *plays* entre os artistas. Um Gini próximo de 0 indica que todos os artistas têm o mesmo espaço na *playlist* (igualdade perfeita); um Gini próximo de 1 indica que poucos artistas dominam a quase totalidade das faixas (desigualdade extrema/monopólio de atenção). O algoritmo ordena os artistas por frequência e calcula a área sob a Curva de Lorenz, permitindo identificar perfis “Superfãs” (alto Gini) versus “Ouvintes Casuais” (baixo Gini).

C) Índice Herfindahl-Hirschman (HHI de Gêneros)

Métrica econômica utilizada para detectar monopólios de mercado ([RHOADES,](#)

1993). Neste estudo, o HHI avaliou a diversidade de gêneros musicais.

$$HHI = \sum_{i=1}^N s_i^2$$

onde s_i é a participação (% do total) de cada gênero musical na biblioteca. Diferentemente do HHI de mercado clássico — cujo limiar de concentração se situa em torno de 0,25 —, aqui o índice é calculado sobre a distribuição de centenas de *tags* explodidas por faixa, o que comprime sua escala por construção: os valores observados situam-se entre 0,02 e 0,08. A leitura é, portanto, **relativa** entre as personas (um HHI comparativamente mais alto indica maior concentração temática, como o *mono-cluster lo-fi* de Daniel) e não o cruzamento de um limiar absoluto de “bolha”.

D) Índice de Jaccard (Similaridade de Conjuntos)

Empregado na etapa de validação cruzada para medir a sobreposição (*overlap*) entre as bibliotecas das diferentes personas.

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

mede a razão entre a interseção (artistas em comum) e a união (total de artistas) dos conjuntos A e B . O objetivo é validar matematicamente o isolamento dos perfis no estado inicial (*Cold Start*): um índice de Jaccard igual a 0,0 entre duas personas comprova que elas ocupam espaços vetoriais disjuntos, garantindo a integridade do grupo de controle.

3.1.2 Síntese Estatística e Definição dos Indicadores Descritivos

Complementarmente à análise matemática de diversidade, foi desenvolvida uma etapa de processamento dedicada à geração de **Resumos Estatísticos Textuais**. O objetivo deste procedimento foi converter os dados brutos de cada *playlist* em relatórios estruturados, consolidando os principais indicadores de desempenho (*KPIs*) que compõem a “Ficha Técnica” de cada persona. Para operacionalizar essa síntese, utilizou-se um *script* Python que computa as estatísticas descritivas fundamentais. Abaixo, definem-se os conceitos operacionais e a interpretação metodológica de cada indicador apresentado nas tabelas de validação:

A) Popularidade Média e Zona de Segurança. Calculada a partir do índice `track_popularity` (0 a 100) fornecido pela API do Spotify, que pondera o número total de reproduções e a recência dessas execuções. Uma média alta (>70) indica um perfil na “Zona de Segurança Algorítmica”; uma média baixa (<20) indica consumo na “Zona de Risco”, onde o algoritmo possui menos dados históricos de engajamento.

B) Consistência Interna (Desvio Padrão da Popularidade). Métrica estatística (σ) que mede a variação dos índices de popularidade dentro da mesma *playlist*.

Um desvio padrão baixo (ex.: $\pm 4,0$) indica curadoria homogênea; um desvio alto indica comportamento errático, misturando *superstars* com artistas desconhecidos.

C) Recência Temporal e Viés de Imediatismo. Análise da distribuição dos anos de lançamento dos álbuns (`release_date`). Perfis com $>80\%$ das faixas na década atual exibem “Viés de Imediatismo”, enquanto perfis ancorados em décadas passadas testam a capacidade do algoritmo de respeitar o “Legado Cultural”.

D) Alcance Médio (Capital Social). Média do número de seguidores (`followers.total`) dos artistas presentes na biblioteca. Serve como *proxy* para o capital econômico e social, distinguindo “Artistas de Estádio” (milhões de seguidores) de “Artistas de Nicho” (milhares).

E) Estrutura (Duração Média). Média da duração das faixas. Faixas curtas ($\sim 2:00$) tendem a ser otimizadas para *streaming* e *looping* (como no *Lo-fi*), enquanto faixas longas ($> 4:30$) indicam resistência à comoditização, priorizando narrativas complexas (como no Rock Progressivo ou *Jazz*).

A automatização desses resumos garante que a caracterização das personas (apresentada na Seção 3.2) seja fundamentada em dados quantitativos auditáveis, estabelecendo uma linha de base rigorosa para o experimento.

3.1.2.1 Tratamento Estatístico Inferencial

Dado que os produtos algorítmicos auditados são intrinsecamente ruidosos e que o desenho experimental opera com um número reduzido de agentes sintéticos ($n = 4$ personas), seguindo a tradição da auditoria de caixa-preta por agentes-sonda (SANDVIG et al., 2014) — na qual a ferramenta AdFisher recorre a testes de permutação justamente porque a saída observada é estocástica (DATTA; TSCHANTZ; DATTA, 2015) —, adotou-se um tratamento inferencial complementar às estimativas pontuais, implementado em `src/analysis/build_significance.py` (semente aleatória fixa para reprodutibilidade). As ferramentas foram escolhidas conforme o nível de agregação de cada métrica, evitando seu uso indevido:

- **Intervalos de confiança de 95% por *bootstrap* de percentis** (EFRON; TIBSHIRANI, 1993) para as **medianas de audiência** (*listeners* e *playcount*), reamostrando-se as faixas com reposição por mil iterações. O *bootstrap* com reposição não é aplicado às métricas de forma (Shannon, Pielou, Gini, riqueza), pois nelas é enviesado para baixo — a essas reserva-se a rarefação.
- **Teste de Mann-Whitney U** (MANN; WHITNEY, 1947) para comparar as distribuições *track-level* de *listeners* entre *input* e *output*, por persona (amostras de

$n \approx 200$ contra $n \approx 270$), reportando-se a estatística U, o p -valor bicaudal e o tamanho de efeito (probabilidade de superioridade).

- **Rarefação por subamostragem sem reposição** (GOTELLI; COLWELL, 2001) para controlar o confundimento de tamanho amostral nas métricas de diversidade/riqueza: cada *output* é subamostrado ao tamanho do *input* ($N = 200$ faixas), mil vezes, recomputando-se riqueza, Shannon, Pielou e Gini.
- **Teste de permutação** (rótulos de persona reembaralhados, com a correção de Phipson e Smyth (2010) para evitar p -valores nulos) para aferir a significância da (não) convergência *cross-persona* medida pelo Índice de Jaccard (Seção 4.5).

Esse arcabouço permite distinguir sinal de ruído amostral em cada afirmação quantitativa do Capítulo 4, conferindo ao estudo o estatuto de auditoria inferencialmente defensável, e não meramente descritiva. Os resultados completos estão em `reports/comparison/` (`significancia.csv`, `significancia_mannwhitney.csv`, `rarefacao.csv`, `jaccard_significancia`).

3.1.3 Adaptação Metodológica: Migração para Fontes Externas (Last.fm + MusicBrainz)

Durante a execução da pesquisa, observou-se que a Spotify Web API sofreu **três ondas progressivas de restrição** ao longo de 2024 e 2026, afetando diretamente os campos centrais utilizados na análise quantitativa do estudo. Este fato, longe de constituir apenas uma limitação operacional, revelou-se um achado original com valor científico próprio, evidenciando empiricamente o argumento central desta pesquisa sobre a opacidade e a governança algorítmica unilateral exercida por plataformas de *streaming*.

Cronologia das restrições documentadas:

1. **Onda 1 (27/11/2024):** a Spotify removeu, para aplicações em modo *development*, o acesso programático às *playlists* algorítmicas (*Daily Mix*, *Discover Weekly*, *Release Radar*, *Made For You*) e ao *endpoint* `/recommendations`. Como contornar essa restrição exigia autorização exclusiva via *Extended Quota Mode* — cujo processo de aprovação tem taxa de sucesso historicamente baixa para projetos acadêmicos —, adotou-se um *workaround* manual: cada persona, após o período de incubação algorítmica, copiou as faixas dos seis *Daily Mixes* gerados pelo sistema para uma “*playlist* espelho” de propriedade da própria conta, viabilizando a leitura via OAuth.
2. **Onda 2 (06/02/2026):** a Spotify anunciou oficialmente novas restrições estruturais ao *Development Mode*: exigência de assinatura *Premium* ativa para o titular da aplicação, limitação a um único *Client ID* por desenvolvedor, restrição a cinco usuários autorizados e migração do *endpoint* `/playlists/{id}/tracks` (depreciado)

para `/playlists/{id}/items`, com regra adicional de que a leitura de itens passa a exigir que o usuário OAuth seja *dono ou colaborador* da *playlist* consultada.

3. **Onda 3 (Fevereiro/2026, sem *changelog* público):** verificação empírica conduzida em 28 de abril de 2026 evidenciou a remoção sistemática dos campos `popularity`, `followers` e `genres` das respostas dos *endpoints* `/artists`, `/tracks`, `/albums` e `/search` para aplicações em *Development Mode*. A confirmação foi obtida em testes controlados com *tokens* OAuth de usuários *Premium* e *Free*, bem como com *Client Credentials*, todos retornando os mesmos campos vazios — comprovando o caráter universal da restrição em nível de aplicação, não em nível de usuário ou plano.

Solução metodológica adotada — fontes externas com mesma metodologia para *Input* e *Output*. A perda dos campos `track_popularity`, `artist_popularity`, `artist_followers` e `artist_genres` comprometeria as métricas centrais (HHI de gêneros, *Long Tail*, Quadrante de Fama, Popularidade Média) caso fossem mantidos exclusivamente os dados extraíveis via Spotify. Para preservar o rigor metodológico e a comparabilidade *Input vs. Output*, a pesquisa adotou um *pipeline* de enriquecimento via **duas fontes externas consagradas**, aplicado consistentemente a ambos os conjuntos de dados:

- **Last.fm** — API gratuita que fornece, para cada artista e cada faixa: número de *listeners* únicos, total de *plays* históricos cumulativos e *top tags* atribuídas pela comunidade. O *endpoint* `artist.getInfo` substituiu o cálculo de popularidade e alcance do artista; o `track.getInfo` substituiu o `track_popularity` do Spotify.
- **MusicBrainz** — banco de dados aberto que fornece metadados ricos sobre artistas: gêneros (*tags crowdsourced*), país de origem, área geográfica, ano de início de carreira (*life-span begin*), tipo de artista (*Person, Group, Choir, Orchestra*) e gênero (*Male, Female, Other*).

A correspondência semântica entre as métricas migradas é descrita na Tabela 1.

Tabela 1 – Correspondência entre métricas do Spotify e substitutos externos (Last.fm/MusicBrainz).

Métrica original (Spotify)	Substituto adotado (Externo)	Justificativa metodológica
<code>track_popularity</code> (índice 0–100)	Last.fm <code>track.listeners</code>	Ouvintes únicos como medida absoluta de alcance da faixa, em escala logarítmica natural.
<code>artist_popularity</code> (índice 0–100)	Last.fm <code>artist.playcount</code>	<i>Plays</i> históricos cumulativos como <i>proxy</i> de popularidade consagrada (não apenas atual).
<code>artist_followers</code> (contagem)	Last.fm <code>artist.listeners</code>	Ouvintes únicos como <i>proxy</i> direto de base de fãs ativa.
<code>artist_genres</code> (lista Spotify) (não existia anteriormente)	MusicBrainz <code>tags</code> (com <i>fallback</i> Last.fm)	<i>Tags crowdsourced</i> de fonte aberta, comparáveis em granularidade.
(não existia anteriormente)	MusicBrainz <code>life-span.begin</code>	Ano de início de carreira do artista — métrica nova que separa “legado” de “newcomers”.
(não existia anteriormente)	MusicBrainz <code>type</code>	Distinção solo (<i>Person</i>) vs. coletivo (<i>Group</i>) — métrica nova de estrutura social do consumo.

Fonte: Elaborado pelo autor (2026).

Impacto na calibração das métricas. Os limiares utilizados na análise de Cauda Longa (*Long Tail*) foram recalibrados via **percentis sobre um *pool* único** que combina os oito conjuntos do estudo (quatro *inputs* + quatro *outputs*, deduplicados por artista), substituindo os limiares absolutos baseados em *followers* do Spotify (cujo intervalo de valores não é diretamente transferível para a escala de *listeners* do Last.fm). Essa régua única — idêntica para *input* e *output* — aumenta a robustez da classificação a mudanças de fonte e, sobretudo, garante que os *tiers* sejam diretamente comparáveis entre estímulo e recomendação.

Cobertura empírica do enriquecimento. O conjunto combinado de *inputs* e *outputs* contém **557 artistas únicos** (contagem global por `primary_artist_name`, sem dupla-contagem entre personas). O enriquecimento alcançou **100% das faixas** com ao menos dados do Last.fm; a cobertura simultânea das *duas* fontes (Last.fm + MusicBrainz) varia por persona — de 86,7% para Sofia (perfil *underground*, menos catalogado no MusicBrainz) a 100% para Beatriz e Ricardo no *output* —, o que constitui, em si, indício do viés de cobertura discutido na Seção 3.4. Os resultados foram persistidos em *cache* incremental para garantir reprodutibilidade.

Implicação epistemológica. O fato de que o próprio instrumental técnico empregado em uma auditoria algorítmica tenha sido sistematicamente obstruído pela plataforma auditada — *durante* a execução da pesquisa, sem aviso público no caso da Onda 3 — constitui *meta-evidência* da assimetria informacional entre plataformas de *streaming* e atores externos (incluindo pesquisadores acadêmicos). Esta observação é retomada na Seção 3.4 como achado central da pesquisa.

3.2 Arquitetura dos Agentes de Teste: Caracterização das Personas Sintéticas

O núcleo experimental desta auditoria reside na implementação de Personas Sintéticas. Estes agentes digitais constituem construções metodológicas desenhadas para representar arquétipos de comportamento musical distintos e polarizados, fundamentais para isolar variáveis específicas do sistema de recomendação, como a popularidade, a recência e a funcionalidade sonora.

Para cobrir um espectro abrangente de hábitos de consumo, foram modelados quatro perfis que operam em extremos opostos da economia da atenção musical: do consumo passivo de sucessos globais à exploração ativa de nichos *underground*. Nas seções subsequentes, cada persona é apresentada através de uma estrutura analítica: perfil psicográfico, que contextualiza a narrativa e humaniza o comportamento simulado; e a motivação científica, que define explicitamente qual hipótese de viés algorítmico está sendo testada. Imediatamente após a caracterização teórica, apresenta-se a validação quantitativa do *input*, onde métricas de popularidade, diversidade e dispersão gráfica confirmam estatisticamente a consolidação de cada arquétipo antes do início da interação com o algoritmo.

3.2.1 Beatriz (A Consumidora Mainstream)

Perfil Psicográfico. Bia é uma verdadeira nativa digital; ela não se lembra de um mundo sem internet ou *smartphones*. Nascida em Uberlândia, sua infância foi marcada pelo YouTube, e sua adolescência, pelo auge do Instagram e a explosão do TikTok. A música, para ela, nunca veio do rádio, mas sim dos *challenges* de dança e das trilhas sonoras virais. Atualmente, com 19 anos, ela é estudante de Relações Internacionais na UFU e personifica o espírito “conectado”. Para Bia, a música é um evento social, um catalisador de interações. É ela quem geralmente conecta o celular na caixa de som nas reuniões com amigos, e estar por dentro dos últimos *hits* brasileiros é essencial para se sentir parte do grupo. Sua relação com a música é imediata e efêmera, focada no presente e no que é compartilhado coletivamente.

Motivação. Esta persona atua como o Grupo de Controle (*Baseline*) do experimento. Beatriz representa o comportamento padrão “ideal” para modelos de negócio baseados em economia da atenção: consumo rápido, alta retenção e foco em sucessos globais. O objetivo é verificar a existência de um ciclo de retroalimentação positivo (*feedback loop*), testando a hipótese de que o sistema de recomendação tende a blindar usuários *mainstream* contra conteúdos de nicho, reforçando uma bolha de alta popularidade e dificultando a serendipidade (descoberta do inesperado).

Validação Quantitativa do Input. A análise estatística dos dados de entrada

confirma a aderência do perfil Beatriz ao arquétipo *Mainstream* brasileiro contemporâneo. A biblioteca apresenta uma Mediana de **194 mil ouvintes únicos no Last.fm** por artista e uma **Mediana de Playcount Histórico de 3,4 milhões** de execuções por artista — patamares característicos da zona de consagração comercial massiva. O viés de recência (do álbum) é extremo: **84,9% das faixas pertencem à década de 2020**, com Ano Médio de Lançamento de 2023, corroborando o perfil de consumo imediatista e focado em novidades virais. A **Mediana de Listeners por Track** alcança **51,8 mil**, valor consistente com faixas que ocupam posições intermediárias-superiores em *rankings* populares brasileiros.

Em termos estruturais, a *playlist* reflete o formato radiofônico padrão, com Duração Média de 3:20, alinhada com as produções comerciais otimizadas para *streaming* e engajamento rápido. A análise de **estrutura social do consumo** (`mb_artist_type`) revela um equilíbrio entre artistas solo (61% *Person*) e bandas/duplas (37% *Group*) — composição típica do *mainstream* brasileiro, onde duplas sertanejas coexistem com solistas *pop*. A **Era de Carreira Mediana dos Artistas é 1993** (cobertura: 51%), refletindo presença de artistas consagrados como Henrique & Juliano e Gustavo Lima, ainda que com forte recência no consumo das faixas específicas.


A diversidade aparente de gêneros (HHI 0,035 sobre *tags* de MusicBrainz) revela, na prática, uma concentração temática brasileira: as *tags* **sertanejo** (64), **brazil/brazilian** (103 combinadas), **pop** (30) e **funk** (23) dominam o repertório, refletindo fielmente os *charts* nacionais. A dispersão de artistas (94 únicos, média de 2,13 faixas por artista) confirma um comportamento de escuta passiva, focado em *hits* diversos em vez de discografias profundas.

Tabela 2 – Indicadores quantitativos do perfil Beatriz (input).

Indicador	Valor Obtido	Interpretação
Listeners Mediano por Artista (Last.fm)	194.228	Zona de consagração massiva; artistas com base de fãs ativa de centenas de milhares.
Playcount Mediano por Artista (Last.fm)	3.434.708	Histórico cumulativo robusto; evidência de validação comercial sustentada no tempo.
Listeners Mediano por Track (Last.fm)	51.879	Faixas com alcance amplo, características de <i>hits</i> radiofônicos.
Entropia de Shannon (Artistas)	6,03 (Alta)	Escuta horizontal pulverizada — padrão “tipo rádio” (<i>Grazing</i>), com baixa fidelidade a artistas específicos.
Coefficiente de Gini	0,42 (Médio)	Distribuição moderadamente desigual de faixas entre artistas; alguns favoritos sem monopolização.
Riqueza (Artistas Únicos)	94	Alta variedade característica do consumo “tipo rádio”.
Era de Carreira Mediana	1993 (cob. 51%)	Mistura de artistas estabelecidos (sertanejo <i>legacy</i>) com novidades virais.
Tipo de Artista (MB)	61% solo, 37% grupo	Equilíbrio típico do <i>mainstream</i> brasileiro.
Recência Temporal (Álbum)	84,9% Anos 2020	Viés de Imediatismo extremo; rejeição ao catálogo profundo.
Tags Dominantes (mb_tags)	sertanejo, brazil, pop, funk	Bolha de filtro geocultural; espelhamento dos <i>charts</i> locais.
HHI de Tags	0,035 (Baixo)	Diversidade aparente, mas concentração temática implícita na predominância brasileira.
Estrutura (Duração)	Média 3:20	Adesão ao formato radiofônico (<i>Radio Edit</i>).


Fonte: Elaborado pelo autor (2026).

Figura 1 – Beatriz (input): distribuição de *listeners* por faixa (Last.fm).




Fonte: Elaborado pelo autor (2026).

Figura 2 – Beatriz (input): distribuição de gêneros (*top tags*).




Fonte: Elaborado pelo autor (2026).

Figura 3 – Beatriz (input): distribuição temporal (era musical das faixas).




Fonte: Elaborado pelo autor (2026).

Figura 4 – Beatriz (input): concentração de artistas (Curva de Lorenz).




Fonte: Elaborado pelo autor (2026).

Figura 5 – Beatriz (input): popularidade vs. alcance dos artistas.



Fonte: Elaborado pelo autor (2026).

Figura 6 – Beatriz (input): distribuição de duração das faixas.



Fonte: Elaborado pelo autor (2026).

3.2.2 Daniel (O Foco Instrumental/Lo-fi)

Perfil Psicográfico. Sempre pragmático e focado, Daniel nunca encarou a música como um componente central de sua identidade cultural, mas sim como uma infraestrutura cognitiva. Formado em Ciência da Computação, foi durante a graduação que descobriu o poder das paisagens sonoras como ferramenta de produtividade. Atualmente com 25 anos e atuando como desenvolvedor de *software*, seu consumo musical é estritamente utilitário. Sua busca na plataforma não é por artistas ou ídolos, mas por “funções”: sonoridades para concentração profunda (*deep work*), batidas de baixa interferência para programação ou frequências relaxantes. Para Daniel, a música não é uma obra de arte a ser contemplada, mas um recurso *bio-hackeável* para otimizar desempenho e modulação de humor.

Motivação Científica. Esta persona foi desenhada para testar a capacidade dos algoritmos de respeitarem contextos funcionais em detrimento da popularidade. Daniel investiga o fenômeno da “Música de Mobília” (*Furniture Music*), onde a faixa serve como plano de fundo. A hipótese central é verificar se o sistema consegue manter a recomendação dentro de parâmetros acústicos específicos (alta instrumentalidade, baixa energia, sem vocais) ou se ocorrerá uma “contaminação *Pop*”, onde o algoritmo tenta inserir faixas com vocais ou artistas famosos que quebram o fluxo de concentração, revelando uma incapacidade de distinguir “gosto musical” de “uso funcional”.

Validação Quantitativa do Input (Linha de Base). Os dados de entrada confirmam a construção de um perfil altamente especializado e, paradoxalmente, anônimo. A biblioteca de Daniel apresenta uma **Mediana de Listeners por Artista de 79,6 mil** (Last.fm) — patamar característico da Cauda Longa do consumo musical — combinada com uma **Mediana de Listeners por Track de apenas 18,8 mil**. Esse contraste

valida o fenômeno da Comoditização Musical: o usuário consome o “gênero” (*Lo-fi Beats*), ignorando completamente quem é o autor da obra.

A estrutura das faixas é radicalmente distinta do padrão *mainstream*. Com **Duração Média de apenas 2:17**, as músicas são projetadas para *looping* contínuo e consumo rápido em *playlists* de estudo. O viés de recência é o mais extremo do estudo: **98,5% das faixas pertencem à década de 2020** (Ano Médio 2024), evidenciando a natureza efêmera e industrial desse gênero, onde milhares de *beats* são lançados diariamente para alimentar algoritmos de foco.


A análise de *tags* revela um **mono-cluster temático**: as marcas *lo-fi* (93 ocorrências), *hip hop* (83), *downtempo* (78) e *instrumental* (77) dominam massivamente. A predominância de **70% artistas solo** (*Person*) confirma o ecossistema de *bedroom producers* — produtores independentes que operam em isolamento, contribuindo individualmente para o catálogo *lo-fi* industrial. A **Era de Carreira Mediana de 1987** (cobertura limitada: 20%, refletindo a invisibilidade de produtores obscuros nos catálogos do MusicBrainz) deve ser interpretada com cautela.

Tabela 3 – Indicadores quantitativos do perfil Daniel (input).

Indicador	Valor Obtido	Interpretação Científica
Listeners Mediano por Artista (Last.fm)	79.595	Zona de Cauda Longa: base de fãs ativa baixa, mas <i>plays</i> altos via consumo passivo.
Playcount Mediano por Artista (Last.fm)	348.630	Histórico cumulativo modesto, característico da era <i>streaming</i> funcional.
Listeners Mediano por Track (Last.fm)	18.824	Faixas projetadas para <i>background listening</i> , sem aspiração a <i>hit</i> cultural.
Entropia de Shannon (Artistas)	6,27 (Máxima do estudo)	Pulverização Funcional; indiferença à autoria — consome-se o “gênero”, não o “artista”.
Coeficiente de Gini	0,37 (Baixo-Médio)	Pouca concentração; distribuição quase uniforme entre os 99 produtores.
Riqueza (Artistas Únicos)	99 (média 2,02 faixas/artista)	Consumo extremamente disperso.
Era de Carreira Mediana	1987 (cob. 20%)	Cobertura limitada — muitos produtores <i>lo-fi</i> sem registro no MusicBrainz; baixa confiabilidade.
Tipo de Artista (MB)	70% solo, 24% grupo	Confirma ecossistema de <i>bedroom producers</i> individuais.
Recência Temporal (Álbum)	98,5% Anos 2020	Produção Industrial/Efêmera; obsolescência rápida do catálogo.
Tags Dominantes (mb+lastfm)	lo-fi, hip hop, downtempo, instrumental	Hiper-especialização cognitiva; bloqueio de vocais e dinâmicas intensas (<i>Deep Work</i>).
HHI de Tags	0,055 (Baixo)	Tags concentradas em poucos termos do mesmo <i>cluster</i> sonoro.
Estrutura (Duração)	Média 2:17	Economia do <i>Stream</i> ; <i>looping</i> contínuo em sessões longas.


Fonte: Elaborado pelo autor (2026).

Figura 7 – Daniel (input): distribuição de *listeners* por faixa (Last.fm).




Fonte: Elaborado pelo autor (2026).

Figura 8 – Daniel (input): distribuição de gêneros (*top tags*).




Fonte: Elaborado pelo autor (2026).

Figura 9 – Daniel (input): distribuição temporal (era musical das faixas).




Fonte: Elaborado pelo autor (2026).

Figura 10 – Daniel (input): concentração de artistas (Curva de Lorenz).




Fonte: Elaborado pelo autor (2026).

Figura 11 – Daniel (input): popularidade vs. alcance dos artistas.



Fonte: Elaborado pelo autor (2026).

Figura 12 – Daniel (input): distribuição de duração das faixas.



Fonte: Elaborado pelo autor (2026).

3.2.3 Sofia (A Consumidora de Nicho)

Perfil Psicográfico. Nascida em 2002, Sofia cresceu na fronteira entre o físico e o digital, mas escolheu habitar os cantos mais silenciosos da internet. Formada em Design Gráfico, ela encara a música não como entretenimento de fundo, mas como uma extensão

direta de sua identidade estética e emocional. Diferente da euforia coletiva de Beatriz, a experiência musical de Sofia é introspectiva e solitária, forjada em fóruns de discussão e *blogs* especializados (como o Rate Your Music) em vez de *feeds* de redes sociais de massa. Ela valoriza a autenticidade, a textura sonora e a “melancolia poética”, buscando ativamente o que é raro. Sua postura é de curadoria ativa: Sofia não espera que o algoritmo lhe diga o que ouvir; ela garimpa, cataloga e preserva suas descobertas como artefatos digitais preciosos, temendo a banalização de seus “tesouros” pelo *mainstream*.

Motivação. Esta persona atua como o Caso de Borda (*Edge Case*) ou o teste da Cauda Longa (*Long Tail*). Sofia representa o desafio de personalização para usuários com gostos altamente específicos e baixa sobreposição com a massa de dados global. O objetivo é testar a capacidade do sistema de recomendação em operar com *data sparsity* (escassez de dados comportamentais coletivos), verificando se o algoritmo consegue manter a coerência estética de nicho ou se sofre de um viés de popularidade, sugerindo artistas famosos incorretamente na tentativa de preencher lacunas. Avalia-se aqui a precisão em micro-gêneros e a sensibilidade a texturas sonoras complexas.

Validação Quantitativa do Input. A análise dos metadados da biblioteca de Sofia confirma rigorosamente seu arquétipo de “Arqueóloga Digital” e consumidora *underground*. A Mediana de Listeners por Track no Last.fm é de apenas **1.223** — três ordens de magnitude abaixo de Beatriz (51.879) e quase 16 vezes menor que Daniel —, evidenciando que a grande maioria de seu consumo reside na obscuridade quase total do catálogo global. A Mediana de Listeners por Artista (59.042) também é a mais baixa do estudo, validando seu interesse pelo cenário independente.

O comportamento de consumo de Sofia é profundamente focado e leal, evidenciado pela **média de 7,41 faixas por artista** (segunda maior, atrás apenas de Ricardo). Enquanto a persona *mainstream* consome *hits* isolados, Sofia consome discografias e álbuns: artistas como S.Maharba, Eterna e Patch+ possuem 15 ou mais faixas cada em sua biblioteca, demonstrando uma escuta vertical e investigativa.


Temporalmente, ela compartilha o viés de contemporaneidade (Ano Médio 2021, com 77% das faixas na década de 2020), mas com um propósito diferente: ela busca a vanguarda experimental atual, não os sucessos de rádio. A distribuição de *tags* valida sua formação em design e gosto por atmosferas: há predominância de estilos baseados em textura e colagem sonora — *shoegaze*, *plunderphonics*, *cloud rap*, *IDM*, *lo-fi indie* — gêneros complexos que exigem análise de conteúdo de áudio (timbre/ritmo) mais apurada do que a simples filtragem colaborativa. A composição **61% solo, 39% grupos** (MusicBrainz) reflete a predominância individual típica de cenas independentes contemporâneas.

Tabela 4 – Indicadores quantitativos do perfil Sofia (input).

Indicador	Valor Obtido	Interpretação Científica
Listeners Mediano por Artista (Last.fm)	59.042	A mais baixa do estudo; isolamento quase total das tendências de massa.
Playcount Mediano por Artista (Last.fm)	565.579	Comunidades de nicho com fãs leais e ativos, gerando <i>plays</i> concentrados em audiência pequena.
Listeners Mediano por Track (Last.fm)	1.223	Três ordens de magnitude abaixo do <i>mainstream</i> ; consumo na obscuridade extrema do catálogo global.
Entropia de Shannon (Artistas)	4,43 (Baixa)	Consumo Imersivo/Vertical; forte oposição à escuta passiva.
Coefficiente de Gini	0,36	Distribuição com algumas favoritas claras (S.Maharba, Eterna, Patch+ com 15+ faixas cada).
Riqueza (Artistas Únicos)	27 (média 7,41 faixas/artista)	Escuta focada em discografia profunda — <i>active listening</i> .
Era de Carreira Mediana	1984 (cob. 41%)	Cena experimental com mistura de pioneiros (anos 80–90) e contemporâneos.
Tipo de Artista (MB)	61% solo, 39% grupo	Predominância de projetos individuais — característico de cenas independentes.
Recência Temporal (Álbum)	77,0% Anos 2020	Vanguarda contemporânea; busca do alternativo no tempo presente.
Tags Dominantes (mb+lastfm)	shoegaze, plunderphonics, cloud rap, IDM, lo-fi indie	Curadoria estético-textural; gêneros de alta complexidade tímbrica.
HHI de Tags	0,024 (Mais baixo do estudo)	Maior diversidade tímbrica/conceitual entre as personas.
Estrutura (Duração)	Média 2:57 (<i>range</i> 0:06–7:04)	Flexibilidade artística; rejeição à padronização (vinhetas a épicos).


Fonte: Elaborado pelo autor (2026).

Figura 13 – Sofia (input): distribuição de *listeners* por faixa (Last.fm).




Fonte: Elaborado pelo autor (2026).

Figura 14 – Sofia (input): distribuição de gêneros (*top tags*).




Fonte: Elaborado pelo autor (2026).

Figura 15 – Sofia (input): distribuição temporal (era musical das faixas).




Fonte: Elaborado pelo autor (2026).

Figura 16 – Sofia (input): concentração de artistas (Curva de Lorenz).




Fonte: Elaborado pelo autor (2026).

Figura 17 – Sofia (input): popularidade vs. alcance dos artistas.



Fonte: Elaborado pelo autor (2026).

Figura 18 – Sofia (input): distribuição de duração das faixas.



Fonte: Elaborado pelo autor (2026).

3.2.4 Ricardo (O Consumidor Nostálgico)

Perfil Psicológico. Nascido em 1982, Ricardo representa a transição da era analógica para a digital. Sua formação musical ocorreu na “Era de Ouro” da indústria fonográfica física (anos 90), moldada pela escassez e pela valorização do objeto: a gravação

de fitas K7, a compra ritualística de LPs e a apreciação de álbuns completos. Como Engenheiro Civil, ele possui uma abordagem estruturada e crítica em relação ao consumo; para ele, a música deve possuir narrativa, complexidade instrumental e autenticidade técnica. Embora utilize o *streaming* por conveniência, sua mentalidade permanece a de um colecionador. Ricardo exibe uma forte resistência algorítmica: ele desconfia da superficialidade das “curadorias automáticas” e prefere atuar como o guardião do “bom gosto” em seu círculo social, utilizando momentos de lazer (como churrascos) para educar as gerações mais novas sobre os clássicos do Rock e da MPB.

Motivação. Esta persona atua como o Controle Temporal (*Legacy Control*) do experimento. Ricardo desafia o sistema de recomendação a lidar com o “Viés de Recência” (*Recency Bias*). O objetivo é verificar se o algoritmo consegue distinguir entre “Alta Popularidade Atual” e “Alta Popularidade Histórica”. Testa-se a capacidade do modelo em recomendar “*Deep Cuts*” (faixas menos conhecidas de artistas famosos) e se ele é capaz de sair do *loop* temporal, sugerindo, por exemplo, bandas novas que tenham a sonoridade “*Classic Rock*” (Greta Van Fleet, por exemplo) ou se ficará preso recomendando apenas reedições das décadas de 70 e 80, gerando um estagnamento de descoberta.

Validação Quantitativa do Input. A análise dos metadados valida robustamente o arquétipo do ouvinte “Saudosista e Leal”. A biblioteca exibe a **Mediana de Listeners por Artista mais alta do estudo — 4,4 milhões** no Last.fm — e uma **Mediana de Playcount Histórico cumulativo de 144,5 milhões**, evidenciando que Ricardo consome “Lendas da Música” e “Gigantes do Estádio” (Metallica, Queen, Rolling Stones, Beatles). A **Mediana de Listeners por Track de 311 mil** corrobora que mesmo as faixas individuais escolhidas são *singles* de grande exposição.

O indicador mais forte de seu comportamento de “escuta de álbum” (em oposição à escuta de *playlist*) é a **Concentração de Artistas**: com apenas **18 artistas únicos para 200 músicas** (média 11,11 faixas/artista), Ricardo apresenta a **menor entropia de Shannon do estudo (4,10) e Gini de 0,18** (mínimo de desigualdade — todos os 18 artistas têm peso comparável). Isso confirma que ele não consome apenas os *greatest hits*, mas mergulha na discografia profunda de seus ídolos (ex.: 16 faixas de Djavan e Metallica).

Temporalmente, o *input* é deslocado para o século passado, com Ano Médio de Lançamento de 1985 e mais de 81% das faixas concentradas entre as décadas de 70, 80 e 90. A análise de **Era de Carreira no MusicBrainz** (cobertura 100% — todos os 18 artistas têm registro completo) confirma com **mediana de 1965** que a seleção concentra-se em artistas que iniciaram carreira na “Era de Ouro” da indústria fonográfica. **66,7% dos artistas são bandas (Group)**, refletindo a centralidade do *band format* no rock clássico, em contraste com a predominância solo das demais personas. Estruturalmente, a *playlist* rejeita a economia da atenção atual: Duração Média de 4:33, com faixas chegando

a quase 9 minutos.

Tabela 5 – Indicadores quantitativos do perfil Ricardo (input).

Indicador	Valor Obtido	Interpretação Científica
Listeners Mediano por Artista (Last.fm)	4.412.516	Zona de consagração histórica; o mais alto do estudo. Lendas globais com milhões de fãs.
Playcount Mediano por Artista (Last.fm)	144.558.091	Histórico cumulativo enorme — décadas de <i>plays</i> acumulados. Validação canônica plena.
Listeners Mediano por Track (Last.fm)	311.105	<i>Singles</i> consagrados; todas as faixas têm exposição internacional sustentada.
Entropia de Shannon (Artistas)	4,10 (Mínima do estudo)	Baixa riqueza (poucos artistas), não concentração: a <i>evenness</i> de Pielou (0,98) confirma distribuição uniforme.
Coeficiente de Gini	0,18 (Mínimo do estudo)	Distribuição quase uniforme entre os 18 artistas — todos com 8–16 faixas.
Riqueza (Artistas Únicos)	18 (média 11,11 faixas/artista)	<i>Album-Oriented Rock</i> — escuta de discografia, não de <i>playlist</i> .
Era de Carreira Mediana (MB)	1965 (cob. 100%)	Era de Ouro da indústria fonográfica; cobertura integral confirma artistas plenamente documentados.
Tipo de Artista (MB)	66,7% grupo, 33,3% solo	Predominância de bandas, refletindo o <i>band format</i> do rock clássico.
Recência Temporal (Álbum)	Ano Médio 1985 (>81% entre 70s–90s)	Cristalização temporal; viés de nostalgia ativo.
Tags Dominantes (mb+lastfm)	rock, classic rock, hard rock, MPB, bossa nova	Purismo analógico; instrumentação orgânica e virtuosismo técnico.
HHI de Tags	0,054	Concentração moderada; <i>cluster</i> temático claro mas não monolítico.
Estrutura (Duração)	Média 4:33 (<i>range</i> 2:02–8:35)	Narrativa progressiva; rejeição à economia da atenção atual.

Fonte: Elaborado pelo autor (2026).

Figura 19 – Ricardo (input): distribuição de *listeners* por faixa (Last.fm).




Figura 20 – Ricardo (input): distribuição de gêneros (*top tags*).






Figura 21 – Ricardo (input): distribuição temporal (era musical das faixas).




Fonte: Elaborado pelo autor (2026).

Figura 22 – Ricardo (input): concentração de artistas (Curva de Lorenz).




Fonte: Elaborado pelo autor (2026).

Figura 23 – Ricardo (input): popularidade vs. alcance dos artistas.



Fonte: Elaborado pelo autor (2026).

Figura 24 – Ricardo (input): distribuição de duração das faixas.



Fonte: Elaborado pelo autor (2026).

3.3 Análise Comparativa e Validação dos Estímulos (Inputs)

Para assegurar a integridade da auditoria, é imperativo validar se as personas geradas representam, de fato, *clusters* comportamentais distintos e independentes. Esta etapa de **Validação Cruzada** (*Cross-Validation*) tem como objetivo demonstrar a or-

togonalidade dos vetores de entrada: comprovar que os quatro perfis ocupam quadrantes separados no espaço vetorial de consumo, minimizando o risco de contaminação cruzada no estágio inicial (*Cold Start*).

Esta validação estabelece a **Linha de Base** (*Baseline*) do experimento. A confirmação de que não há sobreposição significativa entre os conjuntos de dados iniciais é pré-requisito para a inferência causal futura: qualquer convergência (ou divergência) observada nas recomendações (*Outputs*) — seja de conteúdo, de tema ou de magnitude de diversidade — poderá ser atribuída à interferência do algoritmo, e não à similaridade original dos usuários.

3.3.1 Métricas de Diversidade e Entropia da Informação

A aplicação de indicadores de diversidade revela as diferenças estruturais na “dieta informacional” de cada persona. A Tabela 6 apresenta a Entropia de Shannon (incerteza/variedade), a **Evenness de Pielou** ($J = H / \log_2 S$, que normaliza a Shannon pelo seu teto teórico e isola a *uniformidade* da *riqueza*; Pielou (1966)), o Coeficiente de Gini (desigualdade de atenção) e a Riqueza (artistas únicos, S). Estas métricas dependem apenas da contagem de artistas únicos e suas frequências, não foram afetadas pela transição de fonte e mantêm os valores originalmente computados.

Tabela 6 – Métricas de diversidade dos inputs (Shannon, Pielou, Gini, riqueza).

Persona	Shannon	Pielou	Gini	Riqueza (S)	Interpretação Estrutural
Beatriz	6,03 (Alta)	0,92	0,42 (Média)	94	Consumo Exploratório/Caótico; ouvinte de <i>hits</i> , alta rotatividade e baixa fidelidade a álbuns.
Daniel	6,27 (Máxima)	0,95	0,37 (Baixa)	99	Pulverização Funcional; foco na utilidade da “faixa”, não na identidade do “artista”.
Ricardo	4,10 (Mínima)	0,98	0,18 (Mínima)	18	Baixa riqueza, alta uniformidade; Shannon mínima decorre dos poucos artistas (18), não de concentração.
Sofia	4,43 (Baixa)	0,93	0,36 (Baixa)	27	Curadoria Seletiva; foco em <i>Deep Cuts</i> de poucos artistas de nicho (escuta vertical).

Fonte: Elaborado pelo autor (2026).

Análise. O ponto decisivo é que a *Evenness* de Pielou é alta e praticamente plana (0,92–0,98) em todas as personas. Isso significa que as grandes diferenças de Entropia de Shannon entre os perfis (4,10 a 6,27) **não decorrem de diferenças de uniformidade, mas de diferenças de riqueza (S)**: Ricardo tem Shannon baixa porque consome *poucos*

artistas (18), não porque os distribui de forma desigual — ao contrário, sua distribuição é a mais uniforme do estudo. Essa distinção entre riqueza e uniformidade é central para a leitura correta do Capítulo 4, onde se demonstra que a “convergência” da Shannon nos *outputs* é, na verdade, **expansão de riqueza de catálogo** com a *evenness* preservada, e não homogeneização de entropia.

3.3.2 Distribuição de Mercado (Cauda Longa)

A análise da estratificação econômica dos artistas valida a hipótese de polarização entre “Cabeça” (*Head*) e “Cauda” (*Tail*) da distribuição de Pareto. Os limiares de classificação foram **calibrados via percentis sobre um *pool* único** que combina os oito conjuntos do estudo (quatro *inputs* + quatro *outputs*, deduplicados por artista: 557 artistas), resultando em **P25 = 65.376** e **P75 = 474.962** *listeners* no Last.fm. Essa **régua única** — idêntica para *input* e *output* — substitui os limiares absolutos baseados em *followers* do Spotify (deprecados em 02/2026) e torna os *tiers* diretamente comparáveis entre estímulo e recomendação; calibrá-los separadamente por *source* produziria classificações incomparáveis.

Tabela 7 – Distribuição de Cauda Longa dos inputs (régua única de *listeners*).

Persona	% <i>Superstars</i> (>P75)	% Médios (P25–P75)	% Cauda Longa ($\leq$ P25)	Perfil Económico
Beatriz	10,6%	75,5%	13,8%	Consumidora de Massa; concentração em Médios brasileiros (sertanejo, funk).
Ricardo	94,4%	5,6%	0,0%	Consumidor de Legado; foco quase exclusivo em gigantes consagrados.
Daniel	5,1%	54,5%	40,4%	Consumidor Funcional Misto; fronteira entre <i>bedroom producers</i> e produtores estabe-


Análise. O contraste entre Ricardo (94,4% *Superstars*) e Sofia (55,6% Cauda Longa) cria o cenário ideal para auditar o viés econômico: permitirá verificar se o algoritmo tenta forçar uma “gentrificação” do gosto de Sofia, empurrando-a em direção à média de mercado para maximizar a retenção. O uso de uma régua única (*input + output*) também garante que qualquer deslocamento de *tier* observado no Capítulo 4 seja atribuível ao algoritmo, e não a uma diferença de calibração entre os conjuntos.

3.3.3 Análise Visual Cruzada e Topologia dos Dados

As visualizações a seguir sintetizam graficamente as diferenças estruturais entre as quatro personas, comprovando a heterogeneidade da amostra inicial através de uma análise topológica dos dados. O objetivo destas representações é demonstrar a **ortogonalidade dos perfis**: cada persona ocupa uma região distinta no espaço vetorial de consumo.

A) Matriz de Similaridade (Índice de Jaccard). Esta matriz atua como a prova definitiva do isolamento experimental. A predominância absoluta de valores nulos (0,00) ou próximos a zero nas interseções entre personas confirma que não há compartilhamento de repertório, garantindo que o estado de *Cold Start* é único para cada agente.

Figura 25 – Matriz de Similaridade (Índice de Jaccard) entre as personas (input).




Fonte: Elaborado pelo autor (2026).

B) Mapeamento da Economia da Atenção (*Scatter Plot*: Popularidade × Seguidores). Este gráfico espacializa a Teoria da Cauda Longa (*The Long Tail*). O

Quadrante Superior Direito (*Head*) é ocupado por Ricardo e Beatriz, representando o consumo de alta visibilidade e capital social; o Quadrante Inferior Esquerdo (*Tail*), por Sofia e Daniel, representando a zona de obscuridade e nicho. A clara separação visual valida a capacidade do experimento de auditar o viés algorítmico em diferentes estratos de poder econômico.


Figura 26 – Mapeamento da Economia da Atenção: popularidade vs. alcance, por persona (input).



Fonte: Elaborado pelo autor (2026).

C) Cronologia do Consumo (Distribuição Temporal). A visualização de densidade temporal (*KDE Plot*) valida o controle da variável “Tempo”. Observa-se a sobreposição das curvas de Daniel, Beatriz e Sofia na extrema direita (anos 2020), enquanto a curva de Ricardo se isola à esquerda (século XX). Este gráfico serve como linha de base para medir o **Viés de Recência**: deslocamentos futuros da curva de Ricardo para a direita indicarão uma tentativa do sistema de impor novidades a um perfil conservador.


Figura 27 – Cronologia do consumo: distribuição temporal das faixas por persona (KDE, input).



Fonte: Elaborado pelo autor (2026).

D) Curva de Lorenz (Concentração de Artistas). O gráfico ilustra a desigualdade na distribuição de atenção. A curva de Ricardo (mais distante da diagonal perfeita) confirma visualmente sua fidelidade monástica a poucos artistas, enquanto a curva de Beatriz (mais próxima da diagonal) demonstra um consumo pulverizado. Essa métrica será essencial para auditar se o algoritmo respeita a profundidade de catálogo ou se tende a fragmentar a experiência de escuta.

Figura 28 – Concentração de artistas: Curva de Lorenz comparada entre personas (input).



Fonte: Elaborado pelo autor (2026).

3.4 Síntese Metodológica e Limitações

A estrutura metodológica aqui apresentada estabelece um ambiente controlado e auditável para a investigação dos algoritmos de recomendação. A validação estatística dos *inputs* confirma que as quatro personas sintéticas — Beatriz, Daniel, Sofia e Ricardo — constituem instrumentos de medição calibrados, representando vetores de comportamento distintos e isolados.

As métricas de diversidade (Shannon), desigualdade (Gini) e similaridade (Jaccard) calculadas nesta etapa formam a **Linha de Base (Baseline)** do estudo. Nos capítulos subsequentes, esses mesmos indicadores serão reaplicados sobre as listas de recomendação geradas pelo Spotify (*Daily Mix 1–6*), permitindo a comparação *Input vs. Output*.

A comparação direta entre os valores de *Input* (apresentados neste capítulo) e os valores de *Output* (a serem analisados no Capítulo 4) revela o “Delta Algorítmico”: a magnitude e a direção da interferência do sistema sobre o gosto do usuário. Dessa forma, será possível responder aos objetivos da pesquisa, determinando se a plataforma atua como um espelho fiel das preferências do usuário ou como um prisma que distorce a

diversidade cultural em favor de padrões comerciais hegemônicos.

3.4.1 Limitações Metodológicas e Achado Original

A) Pré-requisito não-trivial de Incubação Algorítmica. Verificou-se empiricamente que o sistema do Spotify **não materializa as *playlists* personalizadas** (*Daily Mix*, *Discover Weekly*, *Release Radar*) apenas com base em *likes* e *follows* declarados pelo usuário. A geração desses produtos exige um histórico mínimo de **escuta efetiva**, funcionando como sinal implícito de validação. Para satisfazer este pré-requisito, conduziu-se aproximadamente **40 horas de escuta no modo “Aleatório Inteligente” (*Smart Shuffle*)** por conta-persona — totalizando ~160 horas de incubação somadas. A escolha do *Smart Shuffle* (em detrimento do *shuffle* puro) é deliberada: este modo intercala faixas curtidas com sugestões algorítmicas, garantindo registro de interação tanto com o *input* declarado (*likes*) quanto com recomendações exploratórias. Este pré-requisito constitui uma **observação metodológica original** desta pesquisa, raramente documentada na literatura de auditoria algorítmica musical. Estudos futuros que tentem replicar este *pipeline* sem a etapa de incubação ativa **não conseguirão coletar os *outputs* algorítmicos**.

B) Achado Central — Obstrução Progressiva da API como Meta-Evidência. Durante o período de execução desta pesquisa (2025–2026), a Spotify Web API sofreu **três ondas progressivas e parcialmente não-anunciadas de restrição**, conforme detalhado na Seção 3.1.3: a Onda 1 (Nov/2024) removeu o acesso a *playlists* algorítmicas para *apps* em modo *development*; a Onda 2 (Fev/2026) exigiu *Premium* para o titular do *app*, limitou a 5 usuários autorizados, depreciou o *endpoint* `/playlists/{id}/tracks` e restringiu `/items` a apenas dono ou colaborador; e a Onda 3 (Fev/2026, sem *changelog* público) removeu sistematicamente os campos *popularity*, *followers* e *genres*. A natureza progressiva, parcialmente não-anunciada e unilateral dessas restrições **constitui em si um achado científico relevante**: ela ilustra empiricamente o argumento central da Introdução sobre a **opacidade e a governança algorítmica** das plataformas de *streaming* — o próprio instrumental técnico necessário à auditoria foi sendo obstruído *durante* a execução do experimento. Esta observação configura-se como **meta-evidência** da assimetria informacional entre plataformas e atores externos, alinhando-se ao método etnográfico-experimental de Eriksson et al. (2019) em *Spotify Teardown*, que já denunciava a resistência da plataforma ao escrutínio independente.

C) Resposta Metodológica — *Apples-to-Apples* via Fontes Externas. Para preservar o rigor e a comparabilidade *Input vs. Output*, adotou-se a substituição das métricas comprometidas por dados de **fontes externas consagradas** (Last.fm + MusicBrainz), aplicadas consistentemente aos dois lados da auditoria. Esta solução transforma a limitação em oportunidade — a pesquisa passa a se ancorar em três bases de

dados independentes (Spotify para *tracks*/álbuns/datas; Last.fm para audiência/gêneros; MusicBrainz para *life-span*/tipo/região), aumentando a triangulação metodológica.

D) Outras Limitações.

- **Cobertura do MusicBrainz para *bedroom producers*:** a análise de *life-span* (`mb_career_start`) cobre 100% dos artistas de Ricardo, mas apenas 20% dos de Daniel, refletindo a invisibilidade de produtores *lo-fi* obscuros nos catálogos institucionais.
- **Viés geocultural do Last.fm:** as bases Last.fm e MusicBrainz subcontam artistas brasileiros (sertanejo, funk, indie nacional) frente ao repertório anglófono global. Isso se manifesta nos dados: a cobertura simultânea cai para 86,7% em Sofia, e a composição por país (`mb_country`) varia de 0% de artistas BR em Daniel a 61,8% em Beatriz no *input*. A consequência é que os *listeners/tiers* de artistas brasileiros podem estar subestimados por *artefato de cobertura*; por isso, os deltas *within-persona* são mais defensáveis do que as comparações *cross-persona* de magnitude absoluta.
- **Heterogeneidade da fonte de *tags* (HHI):** o HHI é calculado sobre a melhor fonte de *tags* por faixa, na ordem `mb_tags > lastfm_tags > artist_genres`. A mistura de granularidades introduz ruído menor, reforçando a leitura **relativa** do HHI.
- **Generalização limitada:** os resultados refletem o comportamento do algoritmo do Spotify para perfis brasileiros configurados em abril de 2026; extensões para outros mercados ou momentos exigem replicação independente.
- **Possível variabilidade temporal:** os *Daily Mixes* são atualizados continuamente. A coleta foi feita em janela curta (mesma semana de 28/04/2026) para minimizar variabilidade.

4 Resultados: Análise dos Outputs e o Delta Algorítmico

Concluída a fase de validação dos *inputs* (Capítulo 3), o presente capítulo apresenta a análise empírica dos *outputs* algorítmicos coletados — as faixas que o Spotify recomendou aos quatro perfis sintéticos por meio dos *Daily Mixes*, após o período de incubação descrito na Seção 3.4. O objetivo central deste capítulo é responder à pergunta condutora da pesquisa: **em que magnitude e direção o algoritmo de recomendação distorce o perfil declarado de cada usuário?**

A análise é estruturada em quatro etapas: (i) apresentação descritiva dos *outputs* coletados; (ii) cálculo da Taxa de *Overlap* Interno (redundância dentro da bolha de cada persona); (iii) análise do Delta Algorítmico — comparação direta *Input vs. Output* das treze métricas centrais; e (iv) síntese e teste das quatro hipóteses formuladas por persona no Capítulo 3.

4.1 Apresentação dos Outputs Coletados (Daily Mixes)

Após o período de incubação algorítmica (~ 40 horas de escuta efetiva por persona, em modo *Smart Shuffle*), o sistema do Spotify gerou seis *Daily Mixes* para cada conta. Estas *playlists* foram copiadas manualmente para *playlists* espelho de propriedade de cada persona — *workaround* necessário em virtude da Onda 1 de restrição da API (Seção 3.1.3). Durante o procedimento de cópia, faixas duplicadas entre os seis *mixes* foram automaticamente filtradas pelo próprio cliente do Spotify, gerando o conjunto final consolidado. A Tabela 8 sintetiza o volume de dados coletados.

Tabela 8 – Volume e cobertura dos Outputs.

Persona	Faixas únicas (Output)	Faixas (Input)	Δ tamanho	Artistas únicos (Output)	Cobertura ambas as fontes
Beatriz	276	200	+38,0%	121	100,0%
Daniel	281	200	+40,5%	115	98,6%
Ricardo	268	200	+34,0%	126	100,0%
Sofia	264	200	+32,0%	90	86,7%

Fonte: Elaborado pelo autor (2026).

Observação. O tamanho dos *outputs* é sistematicamente maior que o dos *inputs* (200 faixas) — efeito direto dos seis *Daily Mixes* contendo aproximadamente 50 faixas cada (~ 300 faixas brutas, das quais 6–12% são duplicatas removidas). 100% das faixas

obtiveram ao menos dados do Last.fm; a coluna de cobertura reporta a presença *simultânea* das duas fontes. A cobertura mais baixa de Sofia (86,7%) reflete a menor presença de artistas *underground* no MusicBrainz.

4.2 Taxa de Overlap Interno: Redundância Intra-Persona

Esta métrica original do estudo quantifica quanto o algoritmo “insiste nas mesmas faixas” entre os seis *clusters* (*Daily Mixes*) gerados para uma mesma persona. Operacionalmente, é calculada como:

$$\text{Overlap Interno} = \frac{300 - N}{300}$$

onde N é o número de faixas únicas após *dedupe* (e 300 representa o *pool* bruto estimado de seis *mixes* $\times$ 50 faixas). Quanto maior a taxa, mais redundante é o conjunto de *clusters*.

Tabela 9 – Taxa de Overlap Interno entre os Daily Mixes.

Persona	Faixas únicas (N)	Duplicatas	Taxa de Overlap Interno	Interpretação
Daniel	281	19	6,33%	Variedade alta dentro do nicho <i>lo-fi</i> (muito material disponível).
Beatriz	276	24	8,00%	Variedade moderada (catálogo brasileiro <i>mainstream</i> amplo).
Ricardo	268	32	10,67%	Redundância média (catálogo clássico tem repertório finito de “lendas”).
Sofia	264	36	12,00%	Maior redundância — bolha mais estreita.

Fonte: Elaborado pelo autor (2026).


Indicador exploratório (com ressalvas). O perfil Sofia apresenta a maior taxa de redundância entre as quatro personas, sugerindo que, com menos diversidade no *input* declarado (27 artistas únicos contra 99 de Daniel), o algoritmo tende a repetir faixas entre *clusters*. Esta leitura deve ser tomada como **indicador exploratório, e não como achado consolidado**, por duas limitações estruturais: (i) a métrica é uma transformação determinística e decrescente do número de faixas únicas — fixado o *pool* em 300, $(300 - N)/300$ não acrescenta informação independente do próprio N ; e (ii) a deduplicação entre os seis *Daily Mixes* foi feita automaticamente pelo cliente do Spotify *antes* da contagem, de modo que o valor bruto do *pool* é uma suposição não verificável. A amplitude observada é estreita (6,33% a 12,00%); evita-se, portanto, qualquer leitura causal forte de “bolha de

filtro” a partir deste indicador, reservando-se a evidência de estreitamento às métricas de Jaccard *cross-persona* (Seção 4.5).

4.3 O Delta Algorítmico — Visão Geral

O *Delta Algorítmico* é o resultado quantitativo central deste estudo: a diferença entre o valor de cada métrica no *Output* (recomendações algorítmicas) e no *Input* (perfil declarado pelo usuário), expresso em variação percentual. A Figura 29 condensa os deltas de **treze métricas** × **quatro personas** em uma única visualização.

Figura 29 – Heatmap do Delta Algorítmico Percentual.



Fonte: Elaborado pelo autor (2026).

Cores em vermelho indicam crescimento da métrica do *input* para o *output*; cores em azul indicam queda. Quanto mais saturada, maior a magnitude da variação. A Tabela 10 sintetiza os deltas percentuais.

Tabela 10 – Delta Algorítmico Percentual (Input → Output).

Métrica	Beatriz	Daniel	Ricardo	Sofia
Shannon (Artistas)	+7,9%	+4,0%	+ 61,4%	+ 37,1%
Gini (Artistas)	-5,8%	+0,2%	+ 110,8%	+17,3%
HHI (Tags)	-5,5%	+ 48,2%	-10,5%	-22,8%
Listeners Mediano (Artista)	+6,3%	+ 131,3%	-33,6%	-18,0%
Playcount Mediano (Artista)	+30,6%	+ 263,2%	-59,4%	-30,4%
Listeners Mediano (Track)	-22,5%	-23,6%	+112,4%	+ 405,2%
n. Artistas Únicos	+28,7%	+16,2%	+ 600,0%	+233,3%
% Artistas Solo (Person)	-2,1%	+ 24,7%	-11,9%	-13,5%
% Artistas Grupo (Group)	+1,9%	- 53,2%	+6,0%	+14,3%
Ano Médio (Carreira)	+0,0%	+0,2%	+0,3%	-0,2%
Ano Médio (Release)	-0,1%	-0,0%	+0,0%	+0,1%
Duração Média	-0,2%	+5,2%	-6,9%	+3,1%

Fonte: Elaborado pelo autor (2026).

A leitura horizontal (por métrica) revela quais aspectos do consumo o algoritmo mais distorce; a leitura vertical (por persona) mostra quais perfis sofrem maior interferência.

Nota sobre incerteza (tratamento inferencial, Seção 3.1.2.1). Cada delta “manchete” deste capítulo é acompanhado de sua medida de incerteza, computada em `build_significance.py`. Para as medianas de audiência, reportam-se intervalos de confiança de 95% por *bootstrap* e, quando se comparam distribuições *track-level*, o *p*-valor de Mann-Whitney U. Por exemplo: Daniel, *listeners/artista* 79.595 → 184.082 (+**131,3%**), IC95% *input* [64.290; 111.322] vs. *output* [146.972; 221.535] — sem sobreposição; Sofia, *listeners/track* 1.223 → 6.178 (+**405,2%**), Mann-Whitney $p \approx 1,3 \times 10^{-16}$; Ricardo, *listeners/track* 311.105 → 660.893 (+**112%**), $p \approx 2,1 \times 10^{-7}$. As variações de riqueza (ex.: Ricardo +600%) são qualificadas pela rarefação (Seção 4.5).

Achado preliminar (visão geral). A magnitude da distorção **cresce em ordem inversa ao alinhamento do perfil com o *mainstream***. Beatriz (controle *mainstream*) mostra apenas mudanças tímidas; Daniel (funcional, mas comoditizado) mostra distorções moderadas; Sofia e Ricardo (perfis verticais e desviantes do *mainstream*) sofrem distorções extremas em múltiplas dimensões.


4.4 Análise Persona por Persona

4.4.1 Beatriz (Mainstream) — O Grupo de Controle Validado

A persona Beatriz, projetada como controle *mainstream* brasileiro, exhibe os menores deltas entre as quatro personas. As métricas críticas variam dentro de margens estreitas: Shannon *entropy* +7,9%, *listeners* por artista +6,3%, percentuais de tipo de artista praticamente inalterados (variação <3%). A Figura 30 (KDE de *listeners* por ar-

tista) mostra que as duas distribuições — *input* e *output* — quase se sobrepõem para Beatriz, com leve deslocamento à direita no *output*.

Figura 30 – Distribuição de *Listeners* por Artista (Last.fm), em escala logarítmica, *Input* vs. *Output*.



Fonte: Elaborado pelo autor (2026).

Beatriz: distribuições quase coincidentes; Daniel: deslocamento à direita expressivo (efeito *mainstream*); Ricardo: deslocamento à esquerda (algoritmo encontra artistas menos consagrados); Sofia: deslocamento bimodal sutil.


A leve elevação do `playcount_med_artista` (+30,6%) e dos *listeners* (+6,3%) indica que o algoritmo **adiciona artistas com performance histórica ainda maior**, sem alterar a estrutura geral do perfil. Em termos de *tags*, observa-se manutenção da concentração temática (sertanejo, brasil, pop). A composição solo/grupo mantém o equilíbrio do *input* (~60/40).

Conclusão para Beatriz. O algoritmo “comportou-se bem” — não há distorção significativa do perfil declarado. Esta conclusão é metodologicamente importante: valida o instrumental de medição. Caso Beatriz também apresentasse grandes deltas, seria difícil isolar viés algorítmico de ruído experimental. A baixa interferência sobre o perfil *mainstream* **reforça a confiabilidade dos achados nas demais personas**, onde os deltas são marcadamente maiores.

4.4.2 Daniel (Lo-fi) — Confirmação do Viés de Popularidade

A persona Daniel, projetada como consumidor funcional de *lo-fi beats* (perfil de Cauda Longa funcional), revela o achado mais nítido sobre **viés de popularidade**. Os *listeners* medianos por artista saltam de **79.595 para 184.082** (+131,3%), e o *play-count* mediano salta de **348.630 para 1.266.167** (+263,2%). A Figura 31 torna o efeito visualmente evidente.


Figura 31 – Mediana de *Listeners* por Artista, em escala logarítmica, *Input* vs. *Output*.



Fonte: Elaborado pelo autor (2026).

A coluna vermelha (*Output*) de Daniel é visivelmente maior que a azul (*Input*); inversamente, Ricardo e Sofia têm a coluna *Output* menor. Adicionalmente, a Figura 32 mostra a transformação na estrutura social do consumo.

Figura 32 – Distribuição percentual de Solo (*Person*) vs. Grupo (*Group*) entre artistas únicos.



Fonte: Elaborado pelo autor (2026).

Daniel apresenta queda dramática de % *Group* (de ~24% para ~11%, **-53,2%**), com

correspondente aumento de % Solo (+24,7%). Esta queda de bandas/grupos confirma uma característica estrutural do nicho *lo-fi*: o ecossistema é dominado por *bedroom producers* individuais. O algoritmo, ao “aprender” o perfil de Daniel, acentua essa característica social, recomendando ainda mais produtores solo do que o próprio *input* continha.

Ressalva estatística. A cobertura do campo de tipo de artista (`mb_artist_type`) é satisfatória para Daniel (71,7% no *input*, 93,0% no *output*); o cuidado necessário não é de cobertura, mas de **base absoluta**: a categoria “Grupo” repousa sobre poucos artistas (17 → 12 entre os tipados), e proporções sobre contagens pequenas têm alta variância. O IC de Wilson 95% do % grupo (*input* [15,5%; 35,0%] vs. *output* [6,5%; 18,6%]) apresenta sobreposição, de modo que o delta de −53% deve ser lido como *indício convergente*, e não como evidência isolada. A direção do achado é, porém, corroborada de forma mais robusta pelo aumento de % solo (+24,7%), que se apoia sobre base amostral maior (50 → 94 artistas individuais únicos).

Conclusão para Daniel. Confirma-se a **hipótese de Contaminação Pop**. O algoritmo, ao buscar manter Daniel engajado, recomenda artistas mais conhecidos dentro do nicho *lo-fi*/instrumental — produtores que migraram do anonimato para a “elite do nicho”, evidenciando que a “Zona de Conforto Algorítmico” desloca o perfil em direção ao centro de gravidade da popularidade, mesmo dentro de um *cluster* funcional/comoditizado. Este resultado é coerente com a literatura sobre *popularity bias* em recomendação musical (BAUER; SCHEDL, 2019; KOWALD; SCHEDL; LEX, 2020).


4.4.3 Sofia (Nicho) — Viés do Hit dentro da Cauda Longa

A persona Sofia, projetada como consumidora *underground*/experimental, apresenta o achado mais sutil e revelador do estudo. A análise das três principais métricas relacionadas mostra um padrão paradoxal:

Métrica	Input	Output	Delta
Listeners Mediano por Artista	59.042	48.406	−18,0%
Listeners Mediano por Track	1.223	6.179	+405,2%
n. Artistas Únicos	27	90	+233,3%

À primeira leitura, a queda de −18% nos *listeners* por artista parece sugerir que o algoritmo respeita o nicho de Sofia. Entretanto, a explosão de +405% nos *listeners* por *track* revela um padrão diferente: **o algoritmo respeita o nicho a nível de artista, mas dentro desses artistas, prefere as faixas mais conhecidas**. Em outras palavras, ao invés de recomendar *deep cuts* obscuros (exatamente o comportamento de escuta declarado de Sofia, com média de 7,41 faixas por artista), o sistema recomenda os *singles* mais expostos dos mesmos artistas *indie*. A Figura 33 evidencia que, embora a distribuição temporal permaneça estável, a composição interna da bolha mudou drasticamente.

Figura 33 – Distribuição temporal das faixas por persona (KDE, sobreposição *Input/Output*).



Fonte: Elaborado pelo autor (2026).

Adicionalmente, a expansão do leque de artistas (+233,3%, de 27 para 90 artistas únicos) sugere que o algoritmo **fragmentou o consumo profundo de Sofia**: em vez de deixá-la imersa em discografias completas (S.Maharba, Eterna, Patch+, com 15+ faixas cada no *input*), abriu o leque para artistas adicionais com poucas faixas cada — comportamento típico de “*playlist* exploratória” ao invés de “escuta de álbum”.


Conclusão para Sofia. O algoritmo aplica um **viés de *hit*** dentro da **Cauda Longa**: respeita aparentemente o nicho (artistas igualmente obscuros), mas força um padrão de escuta de “*singles*” sobre o gosto declarado de “obras completas”. Adicionalmente, fragmenta o consumo vertical (poucos artistas, muitas faixas cada) em direção ao consumo horizontal (muitos artistas, poucas faixas cada). Este achado refina a hipótese inicial: a “gentrificação do nicho” não acontece no eixo *artista* (como hipotetizado), mas no eixo *faixa* — uma forma mais sutil de viés que apenas a granularidade *track-level* da fonte Last.fm permitiu capturar.

4.4.4 Ricardo (Nostálgico) — Pulverização da Fidelidade Canônica

A persona Ricardo, projetada como consumidor saudosista (*Album-Oriented Rock* + MPB clássica, 18 artistas com 11,11 faixas/artista em média), exhibe os **maiores deltas de todo o estudo** em três das métricas de diversidade: n. Artistas Únicos

18 $\rightarrow$ 126 (+**600,0%**, o maior delta absoluto em qualquer métrica/persona); Shannon *Entropy* 4,10 $\rightarrow$ 6,61 (+**61,4%**, a maior variação relativa de entropia); e Coeficiente de Gini 0,18 $\rightarrow$ 0,37 (+**110,8%**, duplicação da desigualdade).

Estes números indicam uma **pulverização sistemática da fidelidade canônica** declarada por Ricardo. Ao invés de respeitar o comportamento de “escuta de discografia profunda” (mergulho vertical em poucos ídolos consagrados), o algoritmo expandiu o leque de artistas em sete vezes — recomendando muitos artistas novos com poucas faixas cada, em vez de mais faixas dos mesmos 18 artistas que Ricardo já declarou consumir. A Figura 34 ilustra a transformação no *Top 10* de *tags*.

Figura 34 – Top 10 Tags por Persona, lado a lado: *Input* (azul) vs. *Output* (vermelho).

Fonte: Elaborado pelo autor (2026).

Ricardo mantém o domínio de **rock**, **classic rock**, **hard rock**, mas o *output* introduz *tags* novas como **british**, **progressive rock** e **90s**, ampliando o espectro temático.

Surpreendentemente, os *listeners* e *playcount* medianos por artista **caem** (−33,6% e −59,4%, respectivamente). Isso decorre matematicamente da expansão do leque: os 18 artistas originais de Ricardo (Metallica, Beatles, Queen, etc.) têm milhões de *listeners*; os 108 novos artistas introduzidos pelo algoritmo são em média menos consagrados — abaixando a mediana global, mesmo que cada um individualmente seja popular.

A análise da **Era de Carreira** revela um deslocamento sutil mas significativo: a mediana sobe de **1965 para 1970,5 (+5 anos)**. O algoritmo, mesmo respeitando a temporalidade geral do perfil (Ano Médio do *release* permanece em 1985), modernizou de cinco anos a janela formativa dos artistas recomendados: ao invés de Beatles (carreira iniciada em 1960), introduz Bon Jovi (1983); ao invés de Rolling Stones (1962), introduz Bryan Adams (1976). O perfil “saudosista” continua, mas é discretamente puxado em direção ao final dos anos 1970 e 80.

Conclusão para Ricardo. Confirma-se a hipótese de **violação ativa do “Legacy Control”**. O algoritmo **NÃO respeita o comportamento de fidelidade canônica** — ao contrário, força a substituição de “discografia profunda” por “exploração horizontal de artistas similares”. Este achado tem implicações cruciais para o argumento sobre *bolha de filtro*: contraria a expectativa intuitiva de que perfis ultra-concentrados fariam “presos” em *loops* temporais. Na prática, o algoritmo faz o oposto: **arromba a bolha vertical, fragmenta o gosto consolidado e empurra o usuário em direção a uma horizontalidade comum**.

4.5 Reconfiguração da Diversidade: Expansão de Riqueza com Manutenção de Silos

A análise integrada das quatro personas revela o **achado central deste estudo** — mais sutil e mais robusto do que a hipótese inicial de um “colapso de contexto” entendido como fusão dos perfis. Quando se decompõe a noção de “convergência” em três níveis distintos (conteúdo, tema e magnitude de diversidade), os dados **refutam a homogeneização de conteúdo** e revelam um fenômeno estratificado: o algoritmo expande a riqueza interna de cada perfil e os aproxima *tematicamente*, mas mantém os repertórios de artistas rigidamente separados.

Nível 1 — Conteúdo (artistas): silos preservados, não colapso

A métrica direta da convergência entre personas é o Índice de Jaccard *cross-persona* sobre os conjuntos de artistas. O resultado é inequívoco: o Jaccard médio dos seis pares é **exatamente 0,000 tanto no input quanto no output** — os quatro conjuntos de artistas recomendados são integralmente disjuntos (união de 452 artistas, idêntica à soma dos tamanhos). Um teste de permutação (rótulos de persona reembaralhados, mil reamostragens, correção de [Phipson e Smyth \(2010\)](#)) demonstra que essa separação é **significativamente maior do que a esperada ao acaso**: dado o tamanho dos conjuntos, esperar-se-ia um Jaccard de 0,142 (IC 95% [0,125; 0,161]) por mero sorteio, contra 0,000 observado ($p < 0,001$). Em vez de fundir os perfis, o algoritmo preserva — e estatisticamente acentua — silos de repertório distintos.

Nível 2 — Tema (gêneros/tags): convergência parcial

No nível temático, o quadro se inverte parcialmente: o Jaccard médio de *tags* sobe de **0,128 (*input*) para 0,154 (*output*)**, com aumento em todos os seis pares. Ou seja, embora os artistas permaneçam disjuntos, as recomendações aproximam tematicamente os perfis. Essa dissociação entre proximidade temática e disjunção de artistas é coerente com [Anderson et al. \(2020\)](#), cujo estudo na própria Spotify mede diversidade por proximidade sonora (*embeddings*) e não por riqueza de artistas.

Tabela 11 – Jaccard médio cross-persona (6 pares) vs. nulo de permutação.


Nível de comparação	Jaccard Input	Jaccard Output	Esperado ao acaso (Output)	Veredito
Artistas (conteúdo)	0,000	0,000	0,142 [0,125; 0,161]	Disjunção total; mais segregado que o acaso ($p < 0,001$).
Gêneros/tags (tema)	0,128	0,154	0,201 [0,182; 0,220]	Convergência temática parcial (+20%), porém ainda abaixo do acaso.

Fonte: Elaborado pelo autor (2026).

Nível 3 — Magnitude da diversidade: convergência por expansão de riqueza

Há, de fato, convergência da Entropia de Shannon para um patamar comum ($\sim 6,5$), antes dispersa entre 4,10 e 6,27 — uma redução de $\sim 75\%$ na amplitude entre personas. A Figura 35 e a Tabela 12 sintetizam o fenômeno.

Figura 35 – Shannon *Entropy* de Artistas, *Input* (azul) vs. *Output* (vermelho), com delta % anotado.



Fonte: Elaborado pelo autor (2026).

A linha tracejada cinza marca a faixa de convergência observada ($\sim 6,5$).

Tabela 12 – Convergência da Shannon *Entropy* (e a *evenness* de Pielou).

Persona	Shannon Input	Shannon Output	Δ relativo	Pielou In $\rightarrow$ Out
Beatriz	6,03	6,51	+7,9%	0,92 $\rightarrow$ 0,94
Daniel	6,27	6,52	+4,0%	0,95 $\rightarrow$ 0,95
Ricardo	4,10	6,61	+61,4%	0,98 $\rightarrow$ 0,95
Sofia	4,43	6,07	+37,1%	0,93 $\rightarrow$ 0,93

Fonte: Elaborado pelo autor (2026).

Contudo, **essa convergência não é homogeneização de entropia, e sim expansão de riqueza de catálogo**. A evidência é dupla. Primeiro, a *evenness* de Pielou permanece praticamente constante (0,92–0,98) — para Ricardo, ela inclusive *cai* levemente (0,98 $\rightarrow$ 0,95) enquanto a Shannon dispara, prova de que o ganho vem do número de artistas (18 $\rightarrow$ 126, +600%), não de maior uniformidade. Segundo, o controle por **rarefação** (subamostragem do *output* a $N = 200$ faixas, igual ao *input*; Gotelli e Colwell (2001)) confirma que o efeito não é artefato do maior número de faixas: a riqueza de Ricardo mantém-se em **108 artistas (IC 95% [102; 113])** mesmo sob esforço amostral padronizado, contra 18 no *input*. O efeito persiste com robustez para Ricardo e Sofia; para Daniel, ao contrário, o ganho de Shannon **perde significância após a rarefação** (IC 95% [6,25; 6,44], que contém o valor de *input*, 6,27), indicando que, nesse caso, parte do ganho era mero artefato amostral.

Síntese: a bolha não se funde, alarga-se por dentro

Os três níveis, considerados em conjunto, sustentam um achado mais forte que o originalmente hipotetizado: **o algoritmo não homogeneiza o gosto entre usuários**. Ele expande a riqueza interna de cada perfil (arrombando bolhas verticais, como a de Ricardo) e os aproxima tematicamente, mas mantém repertórios de artistas rigidamente disjuntos. O “Colapso de Contexto” anunciado nos objetivos ocorre apenas no eixo temático e no de *magnitude* de diversidade — não no eixo de conteúdo. A bolha não se rompe nem se funde com as demais: ela se alarga internamente enquanto suas paredes de conteúdo permanecem de pé.

4.6 Síntese dos Achados e Discussão

A Tabela 13 consolida os achados centrais do estudo, mapeando-os contra as hipóteses formuladas por persona no Capítulo 3.

Tabela 13 – Síntese dos Achados por Persona e Hipóteses Confirmadas.

Persona	Hipótese Original	Achado Empírico	Magnitude	Status
Beatriz	<i>Feedback loop</i> positivo blindando contra nicho	Mudanças tímidas, perfil <i>mainstream</i> preservado	Baixa (~5–8%)	Confirmada
Daniel	Contaminação <i>Pop</i> dentro do nicho funcional	<i>Listeners</i> +131%, <i>play-count</i> +263%, % Solo +25%	Alta (~131–263%)	Confirmada
Sofia	Gentrificação do nicho de Cauda Longa	Viés do <i>hit track-level</i> (+405%), fragmentação vertical	Extrema (eixo <i>track</i>)	Confirmada e refinada
Ricardo	Estagnamento de descoberta (<i>loop</i> temporal)	Pulverização (+600%) — oposto da hipótese	Extrema (diversidade)	Refutada e substituída

Fonte: Elaborado pelo autor (2026).

A hipótese de Ricardo merece destaque: o estudo havia antecipado que o algoritmo poderia “ficar preso” em recomendações de eras passadas, gerando estagnamento de descoberta. O resultado empírico aponta o oposto: o algoritmo arromba ativamente a bolha vertical, introduzindo 108 novos artistas (+600%) e modernizando sutilmente a janela temporal (+5 anos na carreira mediana). Este achado é cientificamente mais valioso do que a hipótese original, pois revela uma **direcionalidade não-óbvia** do viés: o algoritmo prefere fragmentar profundidade do que respeitá-la.

4.6.1 Os Quatro Achados Centrais

1. Expansão de Riqueza com Manutenção de Silos. O Spotify converge a *magnitude* de diversidade dos perfis para uma faixa estreita de Shannon (~6,5 *bits*),

mas — como provam a *evenness* de Pielou plana e a rarefação — isso é expansão de riqueza de catálogo, não homogeneização de entropia. Crucialmente, no nível de conteúdo não há convergência alguma: o Jaccard *cross-persona* de artistas é 0,000, mais segregado que o acaso ($p < 0,001$). O algoritmo aproxima os perfis tematicamente (Jaccard de *tags* +20%) enquanto mantém os repertórios de artistas disjuntos. Este é o achado mais robusto e contraintuitivo do estudo.

2. Viés de Popularidade Direcionalmente Dependente. Daniel (perfil moderado de nicho) é puxado *para cima* em *listeners* (+131%); Ricardo (perfil de *superstars*) é puxado *para baixo* (−34%). Em ambos os casos, a direção converge para um patamar médio de visibilidade, evidenciando uma “gravidade algorítmica” que repele os extremos.

3. Viés de *Hit* dentro da Cauda Longa. O algoritmo respeita a Cauda Longa a nível de artista (Sofia mantém artistas obscuros), mas força *hits* a nível de faixa (+405% *listeners* por *track*). A fragmentação do *track-level* é uma forma de viés mais sutil que o eixo *artist-level* não captura.

4. Pulverização da Fidelidade Canônica. Perfis verticais (escuta de álbum) são sistematicamente fragmentados em horizontais (escuta de *playlist*). O algoritmo prefere expansão de catálogo a profundidade discográfica, mesmo quando o sinal de gosto declarado aponta no sentido oposto.

4.6.2 Implicações Teóricas e Sociotécnicas

Os quatro achados, considerados em conjunto, sustentam o argumento central da pesquisa: o algoritmo do Spotify, longe de ser um espelho neutro do gosto declarado, opera como **um prisma com geometria conhecida**. Sua geometria privilegia (i) horizontalidade sobre verticalidade, (ii) artistas medianos sobre extremos (*superstars* ou *underground* absolutos), e (iii) faixas reconhecíveis sobre *deep cuts* — em coerência com o modelo de negócio da Economia da Atenção.

A Onda 3 da restrição da API — que removeu silenciosamente os campos **popularity**, **followers** e **genres** durante a execução desta pesquisa — corrobora institucionalmente o argumento: a plataforma opera para preservar opacidade sobre exatamente as variáveis que permitem auditá-la externamente. Esta meta-evidência confere robustez epistemológica adicional aos achados quantitativos.

A Cauda Longa, central na literatura de economia digital ([ANDERSON, 2006](#)), revela-se acessível apenas parcialmente: o algoritmo permite ao usuário *visitar* artistas de nicho, mas o conduz pelos *singles* consagrados desses artistas — uma forma de “Cauda Longa Curada”. Para o pesquisador interessado em diversidade cultural, não basta perguntar *se* o algoritmo recomenda nicho; é preciso perguntar *como* ele recomenda nicho — preocupação que dialoga com a literatura de *fairness* para fornecedores e a defesa de

marketplaces equilibrados (MEHROTRA et al., 2018).

Diálogo com a literatura. Anderson et al. (2020) reportam que a personalização tende a *reduzir* a diversidade de consumo medida por *embeddings* (proximidade sonora) — aparente contradição com a elevação de diversidade aqui observada. Os resultados são, porém, compatíveis quando se distingue a *riqueza de artistas* (que sobe, por expansão de catálogo) da *proximidade no espaço sonoro* (que pode convergir). O resultado também ressoa com Hosanagar et al. (2014), que observam que sistemas de recomendação podem *aumentar* a comunalidade entre usuários — aqui, essa comunalidade aparece no nível temático (Jaccard de *tags* ↑), mas não no de conteúdo (Jaccard de artistas = 0). Por fim, trabalhos recentes de auditoria e *fairness* em *streaming* musical (TURNBULL et al., 2022; MATROSOVA et al., 2024; SHAKESPEARE; CHAREYRON; ROTH, 2025) confirmam a atualidade do problema.

4.6.3 Limitações Específicas dos Resultados deste Capítulo

Além das limitações gerais já discutidas na Seção 3.4, dois pontos específicos merecem registro:

- **Janela temporal única de coleta:** os *outputs* analisados refletem o estado dos *Daily Mixes* na semana de 28/04/2026; o algoritmo é dinâmico e estes valores podem variar em coletas longitudinais.
- **Cobertura desigual de `mb_career_start`:** a métrica de Era de Carreira tem cobertura integral (100%) para Ricardo, mas baixa (20%) para Daniel (produtores *lo-fi* obscuros frequentemente ausentes do catálogo institucional).

Apesar dessas limitações, a triangulação metodológica adotada (Shannon, Gini, HHI, *Listeners*, *Playcount*, Era de Carreira, Tipo de Artista — sete famílias de métricas independentes) e o uso de duas fontes externas validadas (Last.fm + MusicBrainz) conferem ao conjunto de achados uma robustez que justifica os resultados aqui apresentados como **evidência empírica forte e auditável** da governança algorítmica do Spotify sobre a diversidade musical de seus usuários.

5 Considerações Finais

Este trabalho teve como objetivo geral auditar o comportamento do sistema de recomendação do Spotify, por meio de uma metodologia de caixa-preta com personas sintéticas, a fim de mensurar o impacto da curadoria algorítmica sobre a diversidade cultural. O conjunto de evidências reunido permite responder afirmativamente à pergunta condutora — o algoritmo interfere de modo sistemático e mensurável sobre o gosto declarado —, mas exige refinar a forma como essa interferência é compreendida.

Quanto aos objetivos específicos, todos foram cumpridos. Primeiro, os quatro arquétipos de consumo foram modelados e implementados em contas reais, traduzindo perfis psicográficos em *datasets* controlados. Segundo, a heterogeneidade e o isolamento dos *inputs* foram validados estatisticamente: o Índice de Jaccard nulo entre as personas confirmou a ortogonalidade da linha de base (*cold start*). Terceiro, os metadados das recomendações (*Daily Mixes*) foram coletados e processados, contornando-se a obstrução progressiva da *Web API* por meio de *playlists* espelho e do enriquecimento via Last.fm e MusicBrainz. Quarto, a diversidade e a concentração foram mensuradas por um conjunto triangulado de indicadores — Entropia de Shannon, *evenness* de Pielou, Coeficiente de Gini, HHI e Jaccard —, acompanhados de tratamento estatístico inferencial.

O achado central revelou-se mais sutil do que a hipótese inicial de um “colapso de contexto” entendido como fusão dos perfis. Decomposta a noção de convergência em três níveis, observou-se que: no nível do **conteúdo**, os repertórios de artistas das quatro personas permanecem integralmente disjuntos (Jaccard = 0), de forma estatisticamente mais segregada do que o acaso ($p < 0,001$); no nível **temático**, há convergência parcial de gêneros (Jaccard de *tags* de 0,128 para 0,154); e no nível da **magnitude da diversidade**, a aparente convergência da Entropia de Shannon é, na realidade, expansão de riqueza de catálogo — comprovada pela *evenness* de Pielou praticamente constante e pela análise de rarefação —, e não homogeneização de entropia. Assim, o algoritmo não homogeneiza o gosto entre usuários: ele alarga internamente a bolha de cada perfil e os aproxima tematicamente, mas preserva paredes de conteúdo distintas.

A esse achado somam-se vieses direcionais bem definidos: uma “gravidade algorítmica” que desloca perfis em direção a um patamar médio de popularidade (Daniel, +131% de ouvintes por artista) e um viés de *hit* que, mesmo respeitando a cauda longa no eixo do artista, força as faixas mais expostas no eixo da obra (Sofia, +405% de ouvintes por faixa). De modo contraintuitivo, o perfil de fidelidade canônica (Ricardo) teve sua bolha vertical arrombada, com expansão de 18 para 126 artistas — o oposto do estagnamento temporal hipotetizado.

Como contribuições, o trabalho (i) oferece evidência empírica, inferencialmente sustentada, da geometria de viés do recomendador do Spotify para o mercado brasileiro; (ii) demonstra a importância metodológica de separar *riqueza* de *uniformidade* e *conteúdo* de *tema* na medição de diversidade, evitando conclusões equivocadas a partir da Entropia de Shannon bruta; e (iii) documenta, como meta-evidência, a obstrução progressiva e unilateral da *Web API* durante a própria execução da auditoria — ilustração concreta da opacidade e da assimetria informacional que motivam, sob a ótica da Gestão da Informação, a agenda de auditoria algorítmica.

Reconhecem-se as limitações do estudo: a coleta constitui um *snapshot* temporal único, conduzido com quatro agentes e em um único mercado (Brasil); as fontes externas, sobretudo o Last.fm, apresentam viés de cobertura geocultural que torna as comparações *cross-persona* de magnitude absoluta menos robustas que os deltas *within-persona*; e a métrica de diversidade temática depende de *tags* de granularidade heterogênea.

Como agenda futura, recomendam-se estudos longitudinais que acompanhem a evolução das recomendações ao longo do tempo; a ampliação do número de personas e a replicação em outros mercados culturais; a incorporação de métricas de diversidade baseadas em *embeddings* sonoros, que permitiriam o diálogo direto com a literatura da própria indústria; e a investigação de mecanismos de transparência e auditabilidade que reduzam a assimetria informacional aqui evidenciada. Em síntese, mais do que perguntar *se* o algoritmo recomenda nicho, esta pesquisa demonstra a importância de perguntar *como* ele o faz — distinção decisiva para o debate sobre diversidade cultural na era da governança algorítmica.

Referências

- ANDERSON, A.; MAYSTRE, L.; ANDERSON, I.; MEHROTRA, R.; LALMAS, M. Algorithmic effects on the diversity of consumption on spotify. In: **Proceedings of The Web Conference 2020 (WWW '20)**. New York: Association for Computing Machinery, 2020. p. 2155–2165. Citado 3 vezes nas páginas 16, 64 e 68.
- ANDERSON, C. **The Long Tail: why the future of business is selling less of more**. New York: Hyperion, 2006. Citado 2 vezes nas páginas 15 e 67.
- BAUER, C.; SCHEDL, M. Global and country-specific mainstreamness measures: definitions, analysis, and usage for improving personalized music recommendation systems. **PLoS ONE**, v. 14, n. 6, p. e0217389, 2019. Citado 2 vezes nas páginas 15 e 59.
- BRUNS, A. Filter bubble. **Internet Policy Review**, v. 8, n. 4, 2019. Citado 2 vezes nas páginas 12 e 14.
- DATTA, A.; TSCHANTZ, M. C.; DATTA, A. Automated experiments on ad privacy settings: A tale of opacity, choice, and discrimination. **Proceedings on Privacy Enhancing Technologies**, v. 2015, n. 1, p. 92–112, 2015. Citado 2 vezes nas páginas 16 e 20.
- EFRON, B.; TIBSHIRANI, R. J. **An Introduction to the Bootstrap**. New York: Chapman & Hall/CRC, 1993. (Monographs on Statistics and Applied Probability, 57). ISBN 978-0-412-04231-7. Citado na página 20.
- ERIKSSON, M.; FLEISCHER, R.; JOHANSSON, A.; SNICKARS, P.; VONDERAU, P. **Spotify Teardown: inside the black box of streaming music**. Cambridge, MA: MIT Press, 2019. Citado 2 vezes nas páginas 14 e 51.
- GIL, A. C. **Como elaborar projetos de pesquisa**. São Paulo: Atlas, 1991. Citado na página 17.
- GOTELLI, N. J.; COLWELL, R. K. Quantifying biodiversity: procedures and pitfalls in the measurement and comparison of species richness. **Ecology Letters**, v. 4, n. 4, p. 379–391, 2001. Citado 3 vezes nas páginas 15, 21 e 65.
- HOSANAGAR, K.; FLEDER, D.; LEE, D.; BUJA, A. Will the global village fracture into tribes? recommender systems and their effects on consumer fragmentation. **Management Science**, v. 60, n. 4, p. 805–823, 2014. Citado 2 vezes nas páginas 15 e 68.
- JOST, L. Entropy and diversity. **Oikos**, v. 113, n. 2, p. 363–375, 2006. Citado na página 15.
- KOWALD, D.; SCHEDL, M.; LEX, E. The unfairness of popularity bias in music recommendation: A reproducibility study. In: **Advances in Information Retrieval: 42nd European Conference on IR Research (ECIR 2020)**. Cham: Springer, 2020. (Lecture Notes in Computer Science, v. 12036), p. 35–42. Citado 2 vezes nas páginas 15 e 59.

- MANN, H. B.; WHITNEY, D. R. On a test of whether one of two random variables is stochastically larger than the other. **The Annals of Mathematical Statistics**, v. 18, n. 1, p. 50–60, 1947. Citado na página 20.
- MATROSOVA, K.; MAREY, L.; SALHA-GALVAN, G.; LOUAIL, T.; BODINI, O.; MOUSSALLAM, M. Do recommender systems promote local music? a reproducibility study using music streaming data. **arXiv:2408.16430**, 2024. Citado 2 vezes nas páginas 16 e 68.
- MEHROTRA, R.; MCINERNEY, J.; BOUCHARD, H.; LALMAS, M.; DIAZ, F. Towards a fair marketplace: Counterfactual evaluation of the trade-off between relevance, fairness & satisfaction in recommendation systems. In: **Proceedings of the 27th ACM International Conference on Information and Knowledge Management (CIKM '18)**. New York: Association for Computing Machinery, 2018. p. 2243–2251. Citado 2 vezes nas páginas 15 e 68.
- PARISER, E. **The filter bubble: what the internet is hiding from you**. New York: Penguin Press, 2011. Citado 2 vezes nas páginas 12 e 14.
- PHIPSON, B.; SMYTH, G. K. Permutation p-values should never be zero: Calculating exact p-values when permutations are randomly drawn. **Statistical Applications in Genetics and Molecular Biology**, v. 9, n. 1, p. Article 39, 2010. Citado 2 vezes nas páginas 21 e 63.
- PIELOU, E. C. The measurement of diversity in different types of biological collections. **Journal of Theoretical Biology**, v. 13, p. 131–144, 1966. Citado 2 vezes nas páginas 15 e 44.
- RHOADES, S. A. The herfindahl-hirschman index. **Federal Reserve Bulletin**, v. 79, n. 3, p. 188–189, 3 1993. Citado 2 vezes nas páginas 15 e 19.
- ROSS, A. **The Rest Is Noise: listening to the twentieth century**. New York: Farrar, Straus and Giroux, 2007. Citado na página 11.
- SANDVIG, C.; HAMILTON, K.; KARAHALIOS, K.; LANGBORT, C. **Auditing Algorithms: Research Methods for Detecting Discrimination on Internet Platforms**. 2014. Data and Discrimination: Converting Critical Concerns into Productive Inquiry — pré-conferência do 64º Encontro Anual da International Communication Association (ICA), Seattle. Citado 3 vezes nas páginas 16, 17 e 20.
- SHAKESPEARE, D.; CHAREYRON, V.; ROTH, C. Reframing the filter bubble through diverse scale effects in online music consumption. **Scientific Reports**, v. 15, p. art. 4071, 2025. Citado 2 vezes nas páginas 16 e 68.
- SHANNON, C. E. A mathematical theory of communication. **Bell System Technical Journal**, v. 27, n. 3, p. 379–423, 7 1948. Citado 2 vezes nas páginas 15 e 18.
- TURNBULL, D. R.; MCQUILLAN, S.; CRABTREE, V.; HUNTER, J.; ZHANG, S. Exploring popularity bias in music recommendation models and commercial streaming services. **arXiv:2208.09517**, 2022. Citado 2 vezes nas páginas 16 e 68.

VARGAS, S.; CASTELLS, P. Rank and relevance in novelty and diversity metrics for recommender systems. In: **Proceedings of the 5th ACM Conference on Recommender Systems (RecSys '11)**. New York: Association for Computing Machinery, 2011. p. 109–116. Citado 2 vezes nas páginas [15](#) e [18](#).